PERANCANGAN DATA *WAREHOUSE* UNTUK ANALISIS PENJUALAN MENGGUNAKAN DATASET *GROCERY STORE*

Dosen Pengampu:

Akhmad Irsyad, S.T., M.Kom.

Disusun Oleh:

Kelompok 11

INDAH PUTRI LESTARI	2409116004
ZELSYA RIZQITA RAHMADHINI	2409116022
LARRY POLIN ANUGRAH	2409116026
MAIFARIZA AULIA DYAS	2409116032

PROGRAM STUDI SISTEM INFORMASI

FAKULTAS TEKNIK

UNIVERSITAS MULAWARMAN

2025

DAFTAR ISI

DAFTAR ISI ..... **i**

DAFTAR GAMBAR ..... **iii**

DAFTAR TABEL ..... **iv**

BAB I PENDAHULUAN **1**

1.1. Latar Belakang 1

1.2. Rumusan Masalah 2

1.3. Tujuan Penelitian 2

1.4. Manfaat Penelitian 2

BAB II DATASET DAN PERANCANGAN DATA *WAREHOUSE* **4**

2.1. Deskripsi Dataset 4

2.2. Struktur Data 4

2.3. Perancangan Data *Warehouse* 5

2.4. Desain Tabel 7

BAB III PROSES ETL **10**

3.1. *Extract* 10

3.2. *Transform* 11

3.2.1. Data *Cleansing* 11

3.2.2. Data *Standardization* 18

3.2.3. Data *Validation* 24

3.2.4. Data *Enrichment* 31

3.2.5. Data *Filtering* 32

3.2.6. Data *Aggregation* 34

3.3. Data *Warehouse* (Star Schema) 41

3.4. *Load* 44

BAB IV ANALISIS DATA **46**

4.1. Analisis Jumlah Produk per Kategori 46
4.2. Analisis Rata-rata Harga per Kategori 47
4.3. Analisis Total *Review* per Kategori 48
4.4. Analisis Rata-rata *Rating* per Kategori 49
4.5. Analisis Top 10 Produk Terpopuler 51
BAB V PENUTUP 53
5.1. Kesimpulan 53
5.2. Saran 53

DAFTAR GAMBAR

Gambar 2.1. Skema Data *Warehouse (Star Schema)* 6

Gambar 4.1. Analisis Jumlah Produk per Kategori 46

Gambar 4.2. Analisis Rata-rata Harga per Kategori 47

Gambar 4.3. Analisis Total *Review* per Kategori 48

Gambar 4.4. Analisis Rata-rata *Rating* per Kategori 50

Gambar 4.5. Analisis Top 10 Produk Terpopuler 51

DAFTAR TABEL

Tabel 2.1. Struktur Dataset 4

Tabel 2.2. *Fact Table* 8

Tabel 2.3. *Dimension Category* 8

Tabel 2.4. *Dimension Product* 8

BAB I
PENDAHULUAN

1.1. Latar Belakang

Perkembangan teknologi informasi saat ini membuat hampir setiap kegiatan bisnis menghasilkan data. Hal ini juga terjadi pada sektor ritel seperti *grocery store* atau toko yang menjual berbagai kebutuhan sehari-hari. Dalam proses penjualan produk *grocery*, terdapat berbagai informasi yang dapat dicatat, seperti kategori produk, harga, diskon, serta *rating* pelanggan terhadap produk tersebut.

Namun, data yang tersedia sering kali hanya disimpan tanpa dimanfaatkan secara maksimal. Padahal jika data tersebut diolah dan dianalisis dengan baik, data tersebut dapat memberikan informasi yang berguna bagi perusahaan. Melalui data tersebut, perusahaan dapat mengetahui karakteristik produk, memahami produk yang memiliki *rating* baik, serta melihat bagaimana harga dan diskon dapat mempengaruhi minat pelanggan.

Dalam dunia bisnis saat ini, data menjadi salah satu hal penting yang dapat membantu perusahaan dalam mengambil keputusan. Dengan memanfaatkan data yang tersedia, perusahaan dapat memahami karakteristik produk yang dijual serta mengetahui produk mana yang lebih diminati oleh pelanggan. Informasi tersebut dapat membantu perusahaan dalam menentukan strategi yang lebih baik, seperti menentukan harga produk atau meningkatkan kualitas produk yang ditawarkan.

Salah satu pendekatan yang dapat digunakan untuk mengolah dan menganalisis data bisnis adalah *Business Intelligence*. *Business Intelligence* merupakan proses yang digunakan untuk mengubah data menjadi informasi yang lebih terstruktur sehingga dapat membantu proses analisis dan pengambilan keputusan. Dalam penerapan *Business Intelligence*, salah satu komponen penting yang digunakan adalah data *warehouse*, yaitu tempat penyimpanan data yang telah disusun secara terstruktur sehingga memudahkan proses analisis.

Pada penelitian ini digunakan *Grocery Store Dataset* yang diperoleh dari *platform Kaggle*. Dataset tersebut berisi berbagai informasi mengenai produk *grocery*, seperti *sub category* produk, harga, diskon, *rating* pelanggan, serta deskripsi produk. Data tersebut dapat dimanfaatkan untuk memahami karakteristik produk *grocery* dan memperoleh informasi yang berkaitan dengan produk yang tersedia.

Sebelum data ini dianalisis, terlebih dahulu dilakukan proses ETL (*Extract*, *Transform*, *Load*). Pada tahap *extract*, data diambil dari sumber dataset. Kemudian pada tahap *transform*

dilakukan proses pembersihan dan penyesuaian data agar lebih rapi dan mudah untuk digunakan. Setelah itu, data dimasukkan ke dalam data *warehouse* pada tahap *load* sehingga dapat digunakan untuk proses analisis lebih lanjut.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan sebelumnya, maka rumusan masalah dalam penelitian ini dapat dirumuskan sebagai berikut:

1. Bagaimana proses perancangan data *warehouse* menggunakan dataset *Grocery Store*?
2. Bagaimana proses ETL (*Extract*, *Transform*, *Load*) dilakukan dalam pengolahan data *grocery store*?
3. Bagaimana hasil analisis data penjualan yang diperoleh dari data *warehouse* yang telah dirancang?
4. Informasi apa saja yang dapat diperoleh dari analisis data produk *grocery store*, seperti kategori produk, harga, diskon, dan *rating* pelanggan?

1.3. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah dijelaskan sebelumnya, maka tujuan dari penelitian ini adalah sebagai berikut:

1. Merancang data *warehouse* yang dapat digunakan untuk menyimpan dan mengelola data dari dataset *Grocery Store*.
2. Melakukan proses ETL (*Extract, Transform, Load*) terhadap dataset *grocery store* sehingga data dapat diolah secara lebih terstruktur.
3. Melakukan analisis terhadap data yang telah tersimpan dalam data *warehouse*.
4. Mengidentifikasi informasi yang dapat diperoleh dari data transaksi *grocery* store berdasarkan kategori produk, harga, diskon, dan *rating* pelanggan.

1.4. Manfaat Penelitian

Dengan adanya penelitian ini, diharapkan dapat memberikan beberapa manfaat, baik secara akademis maupun dalam pemahaman pengolahan data penjualan.

1. Bagi penulis, penelitian ini dapat menambah pemahaman mengenai penerapan konsep *Business Intelligence*, khususnya dalam proses pengolahan data menggunakan metode ETL (*Extract, Transform, Load*) dan perancangan data *warehouse*.

2. Bagi pembaca, penelitian ini dapat memberikan gambaran mengenai bagaimana data *grocery store* dapat diolah dan dianalisis sehingga menghasilkan informasi yang lebih terstruktur dan mudah dipahami.
3. Bagi penelitian selanjutnya, hasil dari penelitian ini diharapkan dapat menjadi bahan referensi dalam melakukan penelitian yang berkaitan dengan analisis data, data *warehouse*, maupun penerapan *Business Intelligence* pada dataset yang serupa.

BAB II
DATASET DAN PERANCANGAN DATA *WAREHOUSE*

2.1. Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini merupakan data produk *grocery* yang diperoleh dari sumber publik melalui *platform kaggle*. Dataset ini berisi informasi terkait berbagai produk seperti kategori produk, harga, diskon, *rating*, serta deskripsi produk.

Secara umum, dataset ini memiliki beberapa atribut utama seperti *Sub Category*, *Price*, *Discount*, *Rating*, *Title*, *Currency*, *Feature*, dan *Product Description*. Data tersebut menggambarkan informasi produk yang dijual beserta detail tambahan yang dapat digunakan untuk analisis. Dataset ini masih dalam kondisi mentah, dimana terdapat beberapa nilai yang tidak konsisten, nilai kosong, serta format data yang belum sesuai. Oleh karena itu, diperlukan proses pembersihan dan transformasi data sebelum digunakan dalam pembangunan data *warehouse* dan analisis lebih lanjut.

2.2. Struktur Data

Dataset yang digunakan terdiri dari beberapa atribut yang merepresentasikan informasi produk. Setiap atribut memiliki fungsi untuk menggambarkan karakteristik produk yang akan dianalisis. Berikut merupakan struktur data dari dataset yang digunakan:

Tabel 2.1. Struktur Dataset

No	Nama Kolom	Tipe Data	Keterangan
1	*Sub Category*	*Object* (Teks)	Menunjukkan kategori produk
2	*Price*	*Object* (Teks)	Menunjukkan harga produk
3	*Discount*	*Object* (Teks)	Menunjukkan informasi diskon
4	*Rating*	*Object* (Teks)	Menunjukkan *rating* dan jumlah *review*

5	*Title*	*Object* (Teks)	Nama produk
6	*Currency*	*Object* (Teks)	Mata uang yang digunakan
7	*Feature*	*Object* (Teks)	Informasi fitur produk
8	*Product Description*	*Object* (Teks)	Deskripsi produk

Berdasarkan struktur tersebut, terlihat bahwa seluruh atribut masih menggunakan tipe data teks. Hal ini menunjukkan bahwa data masih dalam kondisi mentah sehingga diperlukan proses transformasi untuk mengubah beberapa atribut menjadi tipe numerik agar dapat digunakan dalam analisis data.

2.3. Perancangan Data *Warehouse*

Perancangan data *warehouse* dilakukan sebelum proses ETL sebagai acuan dalam pengolahan data. Pada perancangan ini digunakan *Star Schema* karena memiliki struktur yang sederhana dan efisien untuk proses analisis data. Skema ini terdiri dari satu *fact table* sebagai pusat data transaksi dan beberapa *dimension table* yang menyimpan informasi pendukung.

A. *Fact Table*

Dalam perancangan ini, tabel fakta yang digunakan adalah *fact_table*, yang berisi data utama yang akan digunakan dalam proses analisis. Tabel ini akan menyimpan informasi penting seperti harga produk (*price*), diskon (*discount*), harga akhir (*final_price*), nilai *rating* (*rating_value*), serta jumlah *review* (*review_count*). Selain itu, tabel ini juga akan menyimpan kunci seperti *Product_ID* dan *Category_ID* yang digunakan untuk menghubungkan tabel fakta dengan tabel dimensi. Data dalam tabel ini menjadi fokus utama dalam proses analisis karena mencerminkan karakteristik produk dan penilaian pelanggan.

B. *Dimension Table*

Dalam perancangan ini, tabel dimensi digunakan untuk menyimpan informasi pendukung yang memberikan konteks terhadap data pada tabel fakta. Tabel dimensi yang akan digunakan terdiri dari tabel kategori dan tabel produk.

Tabel dimensi kategori akan menyimpan informasi mengenai kategori produk, seperti nama kategori yang diidentifikasi melalui *Category_ID*. Sementara itu, tabel dimensi produk akan menyimpan informasi detail produk seperti nama produk (*title*), fitur produk (*feature*), deskripsi produk (*product description*), serta mata uang (*currency*) yang digunakan. Setiap tabel dimensi akan memiliki kunci utama (*primary key*) yang digunakan untuk menghubungkan dengan tabel fakta. Dengan adanya tabel dimensi ini, data menjadi lebih terstruktur dan memudahkan dalam proses analisis berdasarkan kategori maupun detail produk.

C. Skema Data *Warehouse*

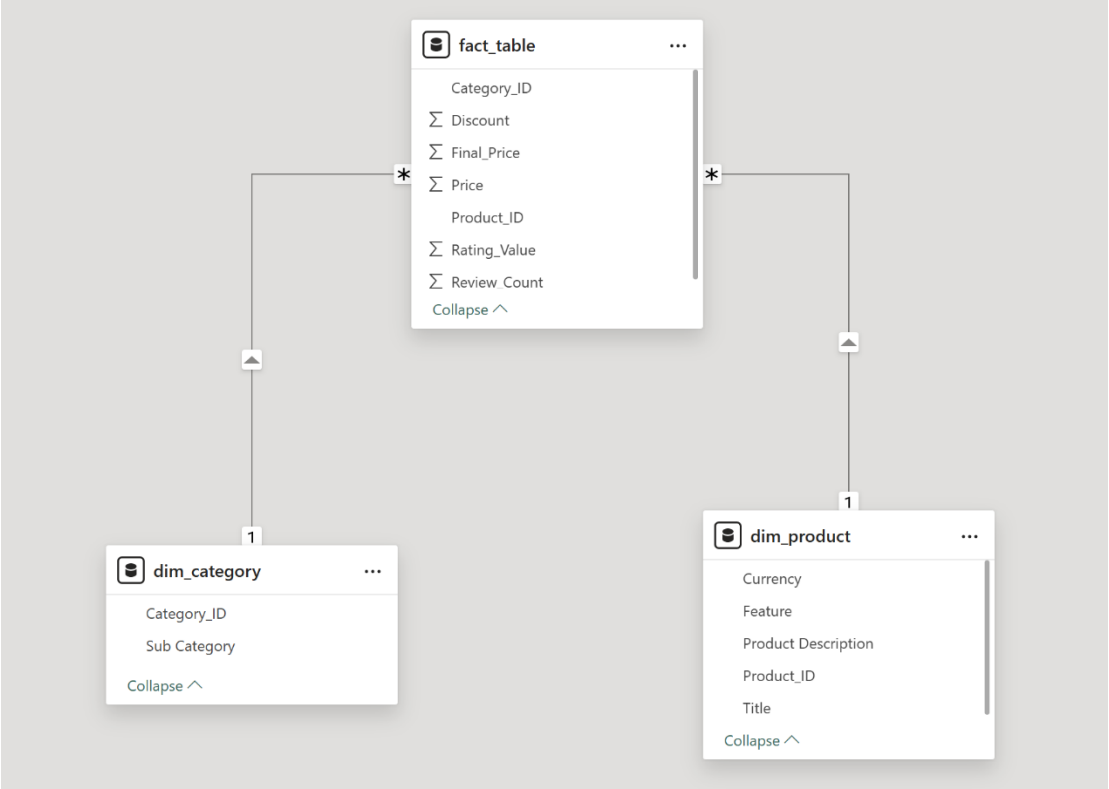

Gambar 2.1. Skema Data *Warehouse* (*Star Schema*)

Berdasarkan gambar di atas, terlihat bahwa Data *Warehouse* yang dibangun menggunakan pendekatan *Star Schema*, di mana terdapat satu tabel fakta yang berada di pusat dan beberapa tabel dimensi yang terhubung langsung.

Tabel *fact_table* berfungsi sebagai pusat penyimpanan data utama yang akan dianalisis. Tabel ini berisi atribut-atribut numerik seperti *price*, *discount*, *final_price*, *rating_value*, dan *review_count*. Atribut-atribut tersebut digunakan untuk melakukan berbagai analisis, seperti analisis harga, efektivitas diskon, serta performa produk berdasarkan *rating* dan jumlah ulasan. Selain itu, tabel ini juga memiliki *Product_ID*

dan *Category_ID* yang berperan sebagai *foreign key* untuk menghubungkan ke tabel dimensi.

Di sisi lain, terdapat tabel *dim_product* yang menyimpan informasi detail terkait produk. Beberapa atribut yang terdapat pada tabel ini antara lain *title*, *product description*, *feature*, dan *currency*. Tabel ini memberikan konteks tambahan terhadap data pada *fact table*, sehingga analisis dapat dilakukan lebih spesifik berdasarkan karakteristik produk. Selain itu, terdapat tabel *dim_category* yang berfungsi untuk menyimpan informasi kategori produk, seperti *Category_ID* dan *Sub Category*. Dengan adanya tabel ini, analisis dapat dilakukan pada tingkat kategori, misalnya untuk mengetahui kategori produk yang memiliki performa terbaik.

Relasi antar tabel pada skema ini bersifat *one-to-many*, di mana satu data pada tabel dimensi dapat berhubungan dengan banyak data pada tabel fakta. Hubungan ini ditunjukkan melalui *Product_ID* dan *Category_ID* yang menghubungkan tabel fakta dengan masing-masing tabel dimensi.

Desain ini divisualisasikan menggunakan *Power BI* setelah proses ETL dilakukan, namun struktur Data *Warehouse* yang ditampilkan merupakan bagian dari tahap perancangan.

D. Relasi Antar Tabel

Dalam perancangan data *warehouse*, relasi antar tabel dibentuk untuk menghubungkan tabel fakta dengan tabel dimensi. Relasi ini akan dilakukan dengan menggunakan kunci utama (*primary key*) pada tabel dimensi dan kunci tamu (*foreign key*) pada tabel fakta.

Tabel fakta akan dihubungkan dengan tabel dimensi kategori melalui *Category_ID*, serta dihubungkan dengan tabel dimensi produk melalui *Product_ID*. Dengan adanya relasi ini, setiap data pada tabel fakta dapat dikaitkan dengan informasi kategori dan detail produk yang terdapat pada tabel dimensi. Struktur relasi ini membentuk pola *star schema*, dimana tabel fakta berada di pusat dan dikelilingi oleh tabel dimensi. Dengan hubungan tersebut, data menjadi lebih terorganisir dan memudahkan dalam proses analisis berdasarkan berbagai atribut yang tersedia.

2.4. Desain Tabel

Pada tahap ini dilakukan perancangan struktur tabel yang akan digunakan dalam data *warehouse*. Setiap tabel dirancang dengan menentukan atribut, tipe data, serta kunci yang digunakan untuk menghubungkan antar tabel.

Tabel 2.2. *Fact Table*

No	Nama Kolom	Tipe Data	Keterangan
1	*Product_ID*	*Integer*	ID produk (*foreign key*)
2	*Category_ID*	*Integer*	ID kategori (*foreign key*)
3	*Price*	*Float*	Harga produk
4	*Discount*	*Float*	Diskon produk
5	*Final_Price*	*Float*	Harga setelah diskon
6	*Rating_Value*	*Float*	Nilai *rating* produk
7	*Review_Count*	*Integer*	Jumlah *review*

Tabel 2.3. *Dimension Category*

No	Nama Kolom	Tipe Data	Keterangan
1	*Category_ID*	*Integer*	*Primary key*
2	*Sub Category*	*Text*	Nama kategori produk

Tabel 2.4. *Dimension Product*

No	Nama Kolom	Tipe Data	Keterangan
1	*Product_ID*	*Integer*	*Primary key*
2	*Title*	*Text*	Nama produk
3	*Feature*	*Text*	Fitur produk

4	*Product Description*	*Text*	Deskripsi produk
5	*Currency*	*Text*	Mata uang

Berdasarkan tabel desain tersebut, setiap tabel memiliki peran masing-masing dalam data *warehouse*, dimana tabel fakta menyimpan data utama dan tabel dimensi menyimpan informasi pendukung.

BAB III
PROSES ETL

3.1. *Extract*

Tahap *Extract* merupakan tahap awal dalam proses ETL yang bertujuan untuk mengambil data dari sumber data yang digunakan dalam penelitian. Pada penelitian ini data diperoleh dari file GroceryDataset.csv yang kemudian diimpor ke dalam Google Colab menggunakan *library Pandas*.

```
import pandas as pd
import numpy as np

# Membaca data
gc = pd.read_csv("GroceryDataset.csv")

gc.head()
```

	Sub Category	Price	Discount	Rating	Title	Currency	Feature	Product Description
0	Bakery & Desserts	$56.99	No Discount	Rated 4.3 out of 5 stars based on 265 reviews.	David's Cookies Mile High Peanut Butter Cake, ...	$	"10"" Peanut Butter Cake\nCertified Kosher OU-...	A cake the dessert epicure will die for!Our To...
1	Bakery & Desserts	$159.99	No Discount	Rated 5 out of 5 stars based on 1 reviews.	The Cake Bake Shop 8" Round Carrot Cake (16-22...	$	Spiced Carrot Cake with Cream Cheese Frosting ...	Due to the perishable nature of this item, ord...
2	Bakery & Desserts	$44.99	No Discount	Rated 4.1 out of 5 stars based on 441 reviews.	St Michel Madeleine, Classic French Sponge Cak...	$	100 count\nIndividually wrapped\nMade in and I...	Moist and buttery sponge cakes with the tradit...
3	Bakery & Desserts	$39.99	No Discount	Rated 4.7 out of 5 stars based on 9459 reviews.	David's Cookies Butter Pecan Meltaways 32 oz, ...	$	Butter Pecan Meltaways\n32 oz 2-Pack\nNo Prese...	These delectable butter pecan meltaways are th...
4	Bakery & Desserts	$59.99	No Discount	Rated 4.5 out of 5 stars based on 758 reviews.	David's Cookies Premier Chocolate Cake, 7.2 lb...	$	"10" Four Layer Chocolate Cake\nCertified Kosh...	A cake the dessert epicure will die for!To the...

Interpretasi:

Kode tersebut digunakan untuk membaca file GroceryDataset.csv menggunakan *library Pandas* dan menyimpannya ke dalam bentuk *dataframe* dengan nama variabel **gc.** Setelah dataset berhasil dimuat, perintah **gc.head()** digunakan untuk menampilkan beberapa baris pertama dari data.

Dari tampilan tersebut dapat dilihat contoh isi pada setiap kolom seperti *Sub Category*, *Price*, *Discount*, *Rating*, *Title*, *Currency*, *Feature*, dan *Product Description*. Tampilan awal ini membantu untuk memahami struktur serta isi dataset sebelum dilakukan proses pembersihan dan pengolahan data pada tahap selanjutnya.

Menampilkan struktur kolom setiap data

gc.info()

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1757 entries, 0 to 1756
Data columns (total 8 columns):
 #   Column               Non-Null Count  Dtype
---  ------               --------------  -----
 0   Sub Category         1757 non-null   object
 1   Price                1754 non-null   object
 2   Discount             1757 non-null   object
 3   Rating               682 non-null    object
 4   Title                1757 non-null   object
 5   Currency             1752 non-null   object
 6   Feature              1739 non-null   object
 7   Product Description  1715 non-null   object
dtypes: object(8)
memory usage: 109.9+ KB
```

Interpretasi:

Hasil dari perintah **df.info()** menunjukkan bahwa dataset terdiri dari 1757 data dengan 8 kolom. Setiap kolom masih memiliki tipe data *object*, sehingga beberapa atribut seperti harga, diskon, dan *rating* kemungkinan masih terbaca sebagai teks dan perlu disesuaikan pada tahap transformasi. Selain itu terlihat bahwa tidak semua kolom terisi penuh. Beberapa atribut memiliki nilai yang hilang, terutama pada *Rating*, serta pada *Price*, *Currency*, *Feature*, dan *Product Description*.

3.2. *Transform*

Tahap *transform* merupakan proses pengolahan data setelah data berhasil diambil dari sumber dataset. Pada tahap ini dilakukan beberapa proses seperti pengecekan kondisi data, pembersihan data, serta penyesuaian format data agar lebih terstruktur dan siap digunakan pada tahap analisis.

3.2.1. Data *Cleansing*

Data *cleansing* merupakan proses pembersihan data untuk memperbaiki atau menghilangkan data yang tidak lengkap, tidak konsisten, atau tidak relevan. Pada tahap ini dilakukan beberapa langkah seperti menangani nilai kosong (*missing value*), menghapus data

duplikat, serta memastikan format data lebih konsisten. Proses ini bertujuan agar dataset menjadi lebih bersih dan siap digunakan untuk tahap analisis selanjutnya.

```
# Mengecek nilai untuk kolom price
gc["Sub Category"].unique()[:20]
```

```
array(['Bakery & Desserts', 'Beverages & Water', 'Breakfast', 'Candy',
       'Cleaning Supplies', 'Coffee', 'Deli', 'Floral', 'Gift Baskets',
       'Household', 'Kirkland Signature Grocery',
       'Laundry Detergent & Supplies', 'Meat & Seafood', 'Organic',
       'Pantry & Dry Goods', 'Paper & Plastic Products', 'Poultry',
       'Seafood', 'Snacks'], dtype=object)
```

Interpretasi:

Kode tersebut digunakan untuk menampilkan nilai kategori yang terdapat pada kolom *Sub Category* tanpa data yang berulang. Hasilnya menunjukkan berbagai kategori produk yang ada dalam dataset.

```
# Mengecek nilai untuk kolom price
gc["Price"].unique()[:10]
```

```
array(['$56.99 ', '$159.99 ', '$44.99 ', '$39.99 ', '$59.99 ', '$74.99 ',
       '$29.99 ', '$62.99 ', '$299.99 ', '$54.99 '], dtype=object)
```

Interpretasi:

Kode tersebut digunakan untuk menampilkan beberapa nilai unik pada kolom *Price*. Dari hasil tersebut terlihat bahwa nilai harga masih mengandung simbol $, sehingga perlu dilakukan pembersihan data agar dapat diubah menjadi format numerik pada tahap

```
# Mengecek nilai untuk kolom discount
gc["Discount"].unique()[:10]
```

```
array(['No Discount', 'After $30 OFF', 'After $5 OFF',
       'This item is not returnable.', 'After $20 OFF', 'After $4.50 OFF',
       'After $4 OFF', 'After $2.80 OFF', 'After $8 OFF',
       'After $3.60 OFF'], dtype=object)
```

Interpretasi:

Kode tersebut digunakan untuk melihat beberapa nilai unik pada kolom *Discount*. Dari hasil tersebut terlihat bahwa nilai diskon ditulis dalam bentuk teks seperti "*No Discount*" dan "*After $30 OFF*", sehingga perlu dilakukan pengolahan lebih lanjut agar nilainya dapat digunakan dalam analisis.

Mengecek nilai untuk kolom rating

gc["Rating"].unique()[:10]

```
array(['Rated 4.3 out of 5 stars based on 265 reviews.',
       'Rated 5 out of 5 stars based on 1 reviews.',
       'Rated 4.1 out of 5 stars based on 441 reviews.',
       'Rated 4.7 out of 5 stars based on 9459 reviews.',
       'Rated 4.5 out of 5 stars based on 758 reviews.',
       'Rated 4.4 out of 5 stars based on 369 reviews.',
       'Rated 4.7 out of 5 stars based on 2241 reviews.',
       'Rated 4.4 out of 5 stars based on 232 reviews.',
       'Rated 4.4 out of 5 stars based on 1679 reviews.',
       'Rated 5 out of 5 stars based on 2 reviews.'], dtype=object)
```

Interpretasi:

Kode tersebut digunakan untuk melihat beberapa nilai unik pada kolom *Rating*. Hasilnya menunjukkan bahwa nilai *rating* masih berupa teks yang berisi informasi nilai *rating* dan jumlah ulasan, sehingga perlu dilakukan pemisahan atau pengolahan lebih lanjut agar nilai *rating* dapat digunakan dalam analisis.

Mengecek nilai unik pada kolom currency

gc["Currency"].unique()

```
array(['$', nan], dtype=object)
```

Interpretasi:

Kode tersebut digunakan untuk melihat nilai yang terdapat pada kolom *Currency*. Hasilnya menunjukkan bahwa nilai mata uang yang digunakan adalah simbol $, namun terdapat juga nilai yang kosong (NaN) pada beberapa data.

```
# Mengecek kolom title
gc["Title"].head(10)
```

	Title
0	David's Cookies Mile High Peanut Butter Cake, ...
1	The Cake Bake Shop 8" Round Carrot Cake (16-22...
2	St Michel Madeleine, Classic French Sponge Cak...
3	David's Cookies Butter Pecan Meltaways 32 oz, ...
4	David's Cookies Premier Chocolate Cake, 7.2 lb...
5	David's Cookies Mango & Strawberry Cheesecake ...
6	La Grande Galette French Butter Cookies, 1.3 l...
7	David's Cookies No Sugar Added Cheesecake & Ma...
8	David's Cookies Brownie and Cookie Combo Pack
9	The Cake Bake Shop 8" Round Chocolate Cake (16...

Interpretasi:

Kode tersebut digunakan untuk menampilkan beberapa data pada kolom *Title*. Dari hasil tersebut terlihat bahwa kolom ini berisi nama produk yang terdapat dalam dataset.

```
# Mengecek nilai pada kolom feature
gc["Feature"].head(5)
```

	Feature
0	"10"" Peanut Butter Cake\nCertified Kosher OU-...
1	Spiced Carrot Cake with Cream Cheese Frosting ...
2	100 count\nIndividually wrapped\nMade in and I...
3	Butter Pecan Meltaways\n32 oz 2-Pack\nNo Prese...
4	"10" Four Layer Chocolate Cake\nCertified Kosh...

Interpretasi:

Kode tersebut digunakan untuk menampilkan beberapa data pada kolom *Feature*. Dari hasil tersebut terlihat bahwa kolom ini berisi informasi tambahan mengenai produk, seperti ukuran, jumlah produk, atau karakteristik lainnya.

```
# Mengecek nilai
gc["Product Description"].head(5)
```

```
                                   Product Description
0        A cake the dessert epicure will die for!Our To...
1        Due to the perishable nature of this item, ord...
2      Moist and buttery sponge cakes with the tradit...
3  These delectable butter pecan meltaways are th...
4        A cake the dessert epicure will die for!To the...

dtype: object
```

Interpretasi:

Kode tersebut digunakan untuk menampilkan beberapa data pada kolom *Product Description*. Kolom ini berisi deskripsi yang menjelaskan informasi atau detail mengenai

```
# Mengecek nilai unik pada kolom feature
gc["Product Description"].str.contains("\n", na=False).sum()
```

```
np.int64(893)
```

Interpretasi:

Kode tersebut digunakan untuk mengecek jumlah data pada kolom *Product Description* yang mengandung karakter baris baru (\n). Hasilnya menunjukkan terdapat 893 data yang memiliki karakter tersebut.

```
# Menampilkan nilai kosong (missing value)
print("Jumlah data yang memiliki nilai kosong:")
print(gc.isnull().sum())
```

```
Jumlah data yang memiliki nilai kosong:
Sub Category              0
Price                     3
Discount                  0
Rating                 1075
Title                     0
Currency                  5
Feature                  18
Product Description      42
dtype: int64
```

Interpretasi:

Kode tersebut digunakan untuk mengetahui jumlah data yang memiliki nilai kosong pada setiap kolom. Dari hasil tersebut terlihat bahwa beberapa kolom masih memiliki nilai kosong, seperti *Price*, *Rating*, *Currency*, *Feature*, dan *Product Description*. Kolom *Rating* memiliki jumlah data kosong paling banyak dibandingkan kolom lainnya. Hal ini menunjukkan bahwa perlu dilakukan penanganan *missing value* pada tahap pembersihan

```
# Mengisi nilai kosong dengan USD
gc["Currency"] = gc["Currency"].fillna("USD")

# Mengisi nilai kosong dengan No Feature
gc["Feature"] = gc["Feature"].fillna("No Feature")

# Mengisi nilai kosong dengan No Description
gc["Product Description"] = gc["Product Description"].fillna("No Description")

print("Jumlah data yang memiliki nilai kosong:")

print(gc.isnull().sum())
```

```
Jumlah data yang memiliki nilai kosong:
Sub Category              0
Price                     3
Discount                  0
Rating                 1075
Title                     0
Currency                  0
Feature                   0
Product Description       0
dtype: int64
```

Interpretasi:

Kode tersebut digunakan untuk menangani nilai kosong pada beberapa kolom. Nilai kosong pada kolom *Currency* diisi dengan USD, kolom *Feature* diisi dengan *No Feature*, dan kolom *Product Description* diisi dengan *No Description*. Setelah proses tersebut dilakukan, pengecekan kembali menunjukkan bahwa tidak ada lagi nilai kosong pada kolom-kolom tersebut. Sementara itu, nilai kosong pada kolom *Price* dan *Rating* belum ditangani karena kedua kolom tersebut masih berbentuk teks. Kolom *Price* masih mengandung simbol $, sedangkan kolom *Rating* masih berupa kalimat yang berisi nilai *rating* dan jumlah ulasan. Oleh karena itu, kedua kolom tersebut perlu diproses terlebih dahulu sebelum dapat dilakukan penanganan nilai kosong.

```
# Menampilkan data yang duplikat
print("Data yang duplikat:")
gc[gc.duplicated()]
```

Data yang duplikat:

	Sub Category	Price	Discount	Rating	Title	Currency	Feature	Product Description
1344	Paper & Plastic Products	$16.19	After $3.80 OFF	NaN	Ziploc Seal Top Freezer Bag, Gallon, 38-count,...	$	Seal Top Bags 1-Gallon Freezer Bags 38 Bag...	4 - 38 Count Boxes\n152 Gallon Freezer Bags To...
1345	Paper & Plastic Products	$16.19	After $3.80 OFF	NaN	Ziploc Seal Top Freezer Bag, Gallon, 38-count,...	$	Seal Top Bags 1-Gallon Freezer Bags 38 Bag...	4 - 38 Count Boxes\n152 Gallon Freezer Bags To...
1346	Paper & Plastic Products	$16.19	After $3.80 OFF	NaN	Ziploc Seal Top Freezer Bag, Gallon, 38-count,...	$	Seal Top Bags 1-Gallon Freezer Bags 38 Bag...	4 - 38 Count Boxes\n152 Gallon Freezer Bags To...

Interpretasi:

Kode tersebut digunakan untuk menampilkan data yang memiliki nilai duplikat pada dataset. Dari hasil tersebut terlihat bahwa terdapat beberapa baris data yang sama persis dengan baris lainnya. Data duplikat seperti ini perlu dihapus agar tidak mempengaruhi hasil analisis.

```
# Menghapus data duplikat
gc = gc.drop_duplicates()
gc[gc.duplicated()]
```

```
Sub Category  Price  Discount  Rating  Title  Currency  Feature  Product Description
```

Interpretasi:

Kode tersebut digunakan untuk menghapus data yang memiliki nilai duplikat pada dataset. Setelah data duplikat dihapus, pengecekan kembali dengan **gc.duplicated()** menunjukkan bahwa tidak ada lagi data yang sama dalam dataset.

```
# Menampilkan ringkasan informasi
gc.describe()
```

	Sub Category	Price	Discount	Rating	Title	Currency	Feature	Product Description
count	1754	1751	1754	682	1754	1754	1754	1754
unique	19	184	42	483	1484	2	1402	1436
top	Snacks	$14.99	No Discount	No Reviews	Kirkland Signature, Organic Almond Beverage, V...	$	No Feature	No Description
freq	293	81	1626	61	3	1749	18	42

Interpretasi:

Kode tersebut digunakan untuk menampilkan ringkasan informasi dari dataset. Dari hasil tersebut dapat dilihat jumlah data, jumlah nilai unik, nilai yang paling sering muncul, serta frekuensinya pada setiap kolom. Informasi ini membantu untuk memahami gambaran umum data, seperti banyaknya kategori produk, variasi harga, serta nilai yang paling sering muncul pada masing-masing kolom.

3.2.2. Data *Standardization*

Data *standardization* merupakan proses menyeragamkan format data agar memiliki bentuk yang konsisten dan lebih mudah digunakan dalam proses analisis. Pada tahap ini dilakukan penyesuaian terhadap beberapa kolom yang masih memiliki format teks atau simbol tertentu, seperti pada kolom *Price* yang masih mengandung simbol $, serta kolom *Rating* yang masih berupa kalimat.

Proses ini dilakukan dengan membersihkan simbol atau teks yang tidak diperlukan dan mengubahnya menjadi format data yang lebih sesuai, misalnya mengubah nilai harga menjadi numerik. Selain itu, standardisasi juga membantu mengurangi perbedaan format data yang dapat menyebabkan kesalahan saat proses analisis. Dengan adanya proses standardisasi, data menjadi lebih terstruktur dan konsisten.

```
# Menyamakan data menjadi huruf kapital
gc["Sub Category"] = gc["Sub Category"].str.strip()
gc["Sub Category"] = gc["Sub Category"].str.title()
gc['Sub Category'].head(5)
```

	Sub Category
0	Bakery & Desserts
1	Bakery & Desserts
2	Bakery & Desserts
3	Bakery & Desserts
4	Bakery & Desserts

Interpretasi:

Kode tersebut digunakan untuk melakukan standardisasi pada kolom *Sub Category*. Fungsi **str.strip()** digunakan untuk menghapus spasi yang tidak diperlukan pada awal atau akhir teks, sedangkan **str.title()** digunakan untuk menyeragamkan penulisan teks agar setiap kata diawali huruf kapital.

```
# Menghapus simbol dolar ($) pada kolom Price
gc["Price"] = gc["Price"].str.replace("$", "", regex=False)
gc['Price'].unique()[:10]
```

```
array(['56.99 ', '159.99 ', '44.99 ', '39.99 ', '59.99 ', '74.99 ',
       '29.99 ', '62.99 ', '299.99 ', '54.99 '], dtype=object)
```

Interpretasi:

Kode tersebut digunakan untuk menghapus simbol $ pada kolom *Price* menggunakan fungsi **str.replace()**. Setelah simbol *dolar* dihapus, nilai pada kolom *Price* hanya berisi angka sehingga lebih mudah diproses.

```
# Mengekstrak angka diskon pada kolom Discount
gc["Discount"] = gc["Discount"].replace({
    "No Discount": "0",
    "This item is not returnable.": "0"
})

gc["Discount"] = gc["Discount"].str.extract(r"(\d+\.?\d*)")
gc["Discount"].unique()[:10]
```

```
array([ 0. , 30. ,  5. , 20. ,  4.5,  4. ,  2.8,  8. ,  3.6,  3. ])
```

Interpretasi:

Kode tersebut digunakan untuk mengekstrak nilai angka pada kolom *Discount*. Beberapa nilai yang sebelumnya berupa teks seperti "*No Discount*" atau "*After $30 OFF*" diubah sehingga hanya menyisakan nilai diskonnya saja. Dari hasil tersebut terlihat bahwa nilai diskon pada dataset kini berupa angka seperti 0, 30, 5, 20, 4.5, 4, 2.8, 8, 3.6, dan 3.

```
# Mengubah nilai "No reviews" menjadi NaN
gc["Rating"] = gc["Rating"].replace("No Reviews", None)

# Memeriksa kembali nilai "No Reviews"
gc["Rating"].str.contains("No Reviews", na=False).sum()
```

```
np.int64(0)
```

Interpretasi:

Kode tersebut digunakan untuk mengganti nilai "*No Reviews*" pada kolom *Rating* menjadi "NaN". Hal ini dilakukan karena nilai tersebut menunjukkan bahwa produk tidak memiliki ulasan, sehingga tidak dapat dianggap sebagai nilai *rating*. Setelah itu dilakukan pengecekan kembali menggunakan **str.contains()** untuk memastikan bahwa teks "*No Reviews*" sudah tidak terdapat lagi pada kolom *Rating*.

```
# Menghapus spasi ganda dan new line (\n)
gc["Title"] = gc["Title"].str.replace(r"\s+", " ", regex=True)
gc["Title"] = gc["Title"].str.replace("\n", " ", regex=False)
gc["Title"] = gc["Title"].str.strip()
gc["Title"].head()
```

	Title
0	David's Cookies Mile High Peanut Butter Cake, ...
1	The Cake Bake Shop 8" Round Carrot Cake (16-22...
2	St Michel Madeleine, Classic French Sponge Cak...
3	David's Cookies Butter Pecan Meltaways 32 oz, ...
4	David's Cookies Premier Chocolate Cake, 7.2 lb...

dtype: object

Interpretasi:

Kode tersebut digunakan untuk membersihkan teks pada kolom *Title*. Spasi ganda dihapus menggunakan **str.replace(),** kemudian karakter *new line* (\n) diubah menjadi spasi agar teks berada dalam satu baris. Setelah itu digunakan **str.strip()** untuk menghapus spasi yang berada di awal atau akhir teks.

```
# Mengubah simbol ($) menjadi USD
gc["Currency"] = gc["Currency"].replace("$", "USD")
```

```
array(['USD'], dtype=object)
```

Interpretasi:

Kode tersebut digunakan untuk melakukan standardisasi pada kolom *Currency* dengan mengganti simbol "$" menjadi "USD". Tujuan dari langkah ini adalah agar penulisan mata uang menjadi lebih jelas dan konsisten dalam bentuk teks. Setelah dilakukan perubahan, nilai pada kolom *Currency* hanya berisi USD.

```
# Menghapus new line (\n), spasi ganda, dan "
gc["Feature"] = gc["Feature"].str.replace("\n", " ", regex=False)
gc["Feature"] = gc["Feature"].str.replace("", "", regex=False)
gc["Feature"] = gc["Feature"].str.replace(r"\s+", " ", regex=True)
gc["Feature"] = gc["Feature"].str.strip()
gc["Feature"].head()
```

	Feature
0	10 Peanut Butter Cake Certified Kosher OU-D 14...
1	Spiced Carrot Cake with Cream Cheese Frosting ...
2	100 count Individually wrapped Made in and Imp...
3	Butter Pecan Meltaways 32 oz 2-Pack No Preserv...
4	10 Four Layer Chocolate Cake Certified Kosher ...

dtype: object

Interpretasi:

Kode tersebut digunakan untuk membersihkan teks pada kolom *Feature*. Karakter *new line* (\n) diubah menjadi spasi, tanda kutip (") dihapus, dan spasi ganda dirapikan menjadi satu spasi. Setelah itu digunakan **str.strip()** untuk menghapus spasi yang berada di awal atau akhir teks.

```
# Menghapus new line (\n) dan spasi ganda
gc["Product Description"] = gc["Product Description"].str.replace("\n", " ", regex=False)
```

```
gc["Product Description"] = gc["Product Description"].str.replace(r"\s+", " ", regex=True)
gc["Product Description"] = gc["Product Description"].str.strip()
gc["Product Description"].head()
```

```
                                Product Description
0       A cake the dessert epicure will die for!Our To...
1       Due to the perishable nature of this item, ord...
2     Moist and buttery sponge cakes with the tradit...
3  These delectable butter pecan meltaways are th...
4        A cake the dessert epicure will die for!To the...

dtype: object
```

Interpretasi:

Kode tersebut digunakan untuk membersihkan teks pada kolom *Product Description*. Karakter *new line* (\n) diubah menjadi spasi dan spasi ganda dirapikan menjadi satu spasi menggunakan fungsi **str.replace()**. Setelah itu digunakan **str.strip()** untuk menghapus spasi yang berada di awal atau akhir teks.

```
gc.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 1754 entries, 0 to 1756
Data columns (total 8 columns):
 #   Column               Non-Null Count  Dtype
---  ------               --------------  -----
 0   Sub Category         1754 non-null   object
 1   Price                1751 non-null   object
 2   Discount             1752 non-null   object
 3   Rating               621 non-null    object
 4   Title                1754 non-null   object
 5   Currency             1754 non-null   object
 6   Feature              1754 non-null   object
 7   Product Description  1754 non-null   object
dtypes: object(8)
```

Dari pengecekkan tipe data terdapat kesalahan tipe data pada kolom *Price*, *Rating*, dan *Discount* yang seharusnya bertipe data numerik.

3.2.3. Data *Validation*

Data *validation* merupakan proses untuk memastikan bahwa data yang telah dibersihkan dan distandarisasi memiliki nilai yang valid serta sesuai dengan kebutuhan analisis. Pada tahap ini dilakukan pengecekan terhadap tipe data, nilai yang tidak wajar, serta memastikan setiap kolom memiliki format data yang sesuai. Proses validasi penting dilakukan untuk memastikan bahwa data yang digunakan sudah benar dan tidak menimbulkan kesalahan pada saat proses analisis.

```
# Mengubah tipe data menjadi numerik
gc["Price"] = pd.to_numeric(gc["Price"], errors="coerce")
gc["Price"].dtype
```

```
dtype('float64')
```

Interpretasi:
Kode tersebut digunakan untuk memastikan bahwa kolom *Price* memiliki tipe data numerik. Fungsi **pd.to_numeric()** digunakan untuk mengubah nilai pada kolom *Price* menjadi angka, sedangkan parameter **errors="coerce"** akan mengubah nilai yang tidak dapat dikonversi menjadi “NaN”. Hasil pengecekan menunjukkan bahwa tipe data kolom *Price* telah berubah menjadi float64, sehingga nilai harga sudah dapat digunakan dalam proses perhitungan atau analisis selanjutnya.

```
# Mengubah tipe data menjadi numerik
gc["Discount"] = pd.to_numeric(gc["Discount"], errors="coerce")
gc["Discount"].dtype
```

```
dtype('float64')
```

Interpretasi:
Kode tersebut digunakan untuk mengubah tipe data pada kolom *Discount* menjadi numerik. Hasil pengecekan menunjukkan bahwa tipe data kolom *Discount* telah berubah menjadi float64, sehingga nilai diskon dapat digunakan dalam proses perhitungan atau analisis data.

```
# Mengekstrak nilai rating
gc["Rating_Value"] = gc["Rating"].str.extract(r"Rated\s([\d\.]+)")

# Mengekstrak jumlah review
gc["Review_Count"] = gc["Rating"].str.extract(r"based on (\d+)")
print(gc[["Rating_Value", 'Review_Count']].head(5))
gc[["Rating_Value", 'Review_Count']].dtypes
```

```
  Rating_Value Review_Count
0          4.3          265
1            5            1
2          4.1          441
3          4.7         9459
4          4.5          758
```

	0
Rating_Value	object
Review_Count	object

Interpretasi:

Kode tersebut digunakan untuk memisahkan informasi pada kolom *Rating* menjadi dua kolom baru, yaitu *Rating_Value* dan *Review_Count*. Nilai *Rating_Value* diambil dari angka *rating* produk, sedangkan *Review_Count* diambil dari jumlah ulasan yang terdapat pada teks *rating*. Hasilnya menunjukkan bahwa nilai *rating* dan jumlah *review* berhasil diekstrak dari teks sehingga informasi tersebut dapat digunakan secara terpisah.

```
# Mengubah tipe data menjadi numerik
gc["Rating_Value"] = pd.to_numeric(gc["Rating_Value"], errors="coerce")
gc["Review_Count"] = pd.to_numeric(gc["Review_Count"], errors="coerce")
gc[["Rating_Value", 'Review_Count']].dtypes
```

	0
Rating_Value	float64
Review_Count	float64

Interpretasi:

Kode tersebut digunakan untuk mengubah tipe data pada kolom *Rating_Value* dan *Review_Count* menjadi numerik. Hasilnya menunjukkan bahwa kedua kolom tersebut telah memiliki tipe data float64.

```
# Mengisi nilai kosong pada kolom Rating_Value dan Review_Count
gc["Review_Count"] = gc["Review_Count"].fillna(0)
gc["Rating_Value"] = gc["Rating_Value"].fillna(0)

# Mengubah tipe data Review_Count menjadi Integer
gc["Review_Count"] = gc["Review_Count"].astype(int)
gc[["Rating_Value", 'Review_Count']].dtypes
```

	0
Rating_Value	float64
Review_Count	int64

Interpretasi:

Kode tersebut digunakan untuk menangani nilai kosong pada kolom *Rating_Value* dan *Review_Count* dengan mengisinya menggunakan nilai 0. Hal ini dilakukan agar tidak terdapat nilai kosong yang dapat mempengaruhi proses analisis. Setelah itu, tipe data pada kolom *Review_Count* diubah menjadi integer karena nilai tersebut merepresentasikan jumlah ulasan. Hasilnya menunjukkan bahwa *Rating_Value* bertipe float64, sedangkan *Review_Count* bertipe int64.

```
# Mengecek apakah masih ada spasi ganda atau karakter new line (\n)
print("Jumlah yang mengandung spasi ganda:", gc["Title"].str.contains(r"\s{2,}",
na=False).sum())

print("Jumlah yang mengandung new line:", gc["Title"].str.contains("\n",
```

```
Jumlah yang mengandung spasi ganda: 0
Jumlah yang mengandung new line: 0
```

Interpretasi:

Kode tersebut digunakan untuk memeriksa apakah masih terdapat spasi ganda atau karakter *new line* (\n) pada kolom *Title*. Hasil pengecekan menunjukkan nilai 0, yang berarti tidak terdapat lagi spasi ganda maupun karakter *new line* pada kolom tersebut.

```
# Menghitung jumlah data pada setiap kategori produk
gc["Sub Category"].value_counts()
```

Sub Category	count
Snacks	293
Pantry & Dry Goods	171
Candy	154
Beverages & Water	148
Meat & Seafood	144
Kirkland Signature Grocery	122
Coffee	95
Cleaning Supplies	94
Gift Baskets	89
Paper & Plastic Products	85
Household	81
Floral	75
Seafood	47
Laundry Detergent & Supplies	39
Bakery & Desserts	33
Organic	33
Breakfast	21
Deli	21
Poultry	9

Interpretasi:

Kode tersebut digunakan untuk mengetahui jumlah produk pada setiap kategori yang terdapat dalam dataset. Dari hasil tersebut terlihat bahwa kategori *Snacks* memiliki jumlah produk paling banyak yaitu 293 data, diikuti oleh *Pantry & Dry Goods* (171) dan *Candy* (154). Sementara itu, beberapa kategori memiliki jumlah produk yang lebih sedikit seperti *Breakfast*, *Deli*, dan *Poultry*. Informasi ini memberikan gambaran mengenai distribusi jumlah produk pada setiap kategori dalam dataset.

```
# Menampilkan nilai unik dan tipe data
gc["Currency"].unique()
```

```
array(['USD'], dtype=object)
```

Interpretasi:

Kode tersebut digunakan untuk menampilkan nilai unik yang terdapat pada kolom *Currency*. Hasilnya menunjukkan bahwa seluruh data menggunakan mata uang USD, sehingga nilai mata uang pada dataset sudah konsisten.

```
# Kolom Feature
print("Kolom Feature")
print("Jumlah yang mengandung spasi ganda:", gc["Feature"].str.contains(r"\s{2,}",
na=False).sum())
print("Jumlah yang mengandung new line:", gc["Feature"].str.contains("\n",
na=False).sum())

# Kolom Product Description
print("\nKolom Product Description")
print("Jumlah yang mengandung spasi ganda:", gc["Product
Description"].str.contains(r"\s{2,}", na=False).sum())
print("Jumlah yang mengandung new line:", gc["Product Description"].str.contains("\n",
na=False).sum())
```

```
Kolom Feature
Jumlah yang mengandung spasi ganda: 0
Jumlah yang mengandung new line: 0

Kolom Product Description
Jumlah yang mengandung spasi ganda: 0
Jumlah yang mengandung new line: 0
```

Interpretasi:

Kode tersebut digunakan untuk memeriksa apakah masih terdapat spasi ganda atau karakter *new line* (\n) pada kolom *Feature* dan *Product Description*. Hasil pengecekan menunjukkan

menunjukkan nilai 0, yang berarti tidak terdapat lagi spasi ganda maupun karakter *new line* pada kedua kolom tersebut.

# Verifikasi Hasil Data Validation
gc.info()

```
<class 'pandas.core.frame.DataFrame'>
Index: 1754 entries, 0 to 1756
Data columns (total 10 columns):
 #   Column               Non-Null Count  Dtype
---  ------               --------------  -----
 0   Sub Category         1754 non-null   object
 1   Price                1732 non-null   float64
 2   Discount             1752 non-null   float64
 3   Rating               621 non-null    object
 4   Title                1754 non-null   object
 5   Currency             1754 non-null   object
 6   Feature              1754 non-null   object
 7   Product Description  1754 non-null   object
 8   Rating_Value         1754 non-null   float64
 9   Review_Count         1754 non-null   int64
dtypes: float64(3), int64(1), object(6)
```

Interpretasi:

Beberapa kolom seperti *Price*, *Discount*, *Rating_Value*, dan *Review_Count* sudah memiliki tipe data numerik. Penambahan kolom *Rating_Value* dan *Review_Count* juga menunjukkan bahwa informasi *rating* telah berhasil dipisahkan dari kolom *Rating*. Hal ini menunjukkan bahwa data telah melalui proses validasi.

# Menampilkan kembali missing value
print(gc.isnull().sum())

```
Sub Category              0
Price                    22
Discount                  2
Rating                 1133
Title                     0
Currency                  0
Feature                   0
Product Description       0
Rating_Value              0
Review_Count              0
dtype: int64
```

Interpretasi:

Dari hasil tersebut terlihat bahwa beberapa kolom seperti *Price*, *Discount*, dan *Rating* masih memiliki nilai kosong. Kolom *Price* memiliki 22 data kosong, *Discount* memiliki 2 data kosong, dan *Rating* memiliki 1133 data kosong. Sementara itu, kolom lainnya seperti *Sub Category*, *Title*, *Currency*, *Feature*, *Product Description*, *Rating_Value*, dan *Review_Count* tidak memiliki nilai kosong. Informasi ini menunjukkan kondisi kelengkapan data setelah proses pembersihan dan validasi dilakukan.

```
# Mengisi nilai kosong dengan nilai median
gc["Price"] = gc["Price"].fillna(gc["Price"].median())

# Mengisi nilai kosong dengan nilai 0
gc["Discount"] = gc["Discount"].fillna(0)

print(gc.isnull().sum())
```

```
Sub Category              0
Price                     0
Discount                  0
Rating                 1133
Title                     0
Currency                  0
Feature                   0
Product Description       0
Rating_Value              0
Review_Count              0
dtype: int64
```

Interpretasi:

Nilai kosong pada kolom *Price* diisi menggunakan nilai median dari kolom tersebut agar nilai harga tetap berada pada kisaran data yang ada. Sementara itu, nilai kosong pada kolom *Discount* diisi dengan 0, yang menunjukkan bahwa produk tersebut tidak memiliki diskon. Setelah proses ini dilakukan, pengecekan kembali menggunakan **gc.isnull().sum()** dilakukan untuk memastikan bahwa nilai kosong pada kedua kolom tersebut sudah berhasil diisi.

3.2.4. Data *Enrichment*

Data *enrichment* merupakan proses penambahan atau pengembangan informasi pada dataset agar data menjadi lebih lengkap dan mudah digunakan dalam analisis. Pada tahap ini dilakukan pembuatan beberapa atribut baru berdasarkan pengolahan data yang sudah ada. Proses ini dilakukan dengan mengolah nilai-nilai yang tersedia menjadi informasi baru yang lebih ringkas dan mudah dipahami, seperti hasil perhitungan serta pengelompokan data ke dalam beberapa kategori. Dengan cara ini, data yang awalnya masih berupa nilai mentah dapat diubah menjadi informasi yang lebih terstruktur.

```
# Membuat kolom Final_Price (harga setelah diskon)
gc["Final_Price"] = gc["Price"] - gc["Discount"]
gc["Final_Price"] = gc["Final_Price"].clip(lower=0)

# Membuat kategori rating
gc["Rating_Category"] = pd.cut(
    gc["Rating_Value"],
    bins=[0, 2, 4, 5],
    labels=["Low", "Medium", "High"]
)

# Membuat kolom Popularity
gc["Popularity"] = gc["Review_Count"]

# Membuat kategori popularitas berdasarkan jumlah review
gc["Popularity_Category"] = pd.cut(
    gc["Review_Count"],
    bins=[0, 50, 200, 10000],
    labels=["Low", "Medium", "High"]
)

# Verifikasi Hasil Data Enrichment
print(gc.head())
```

```
        Sub Category   Price  Discount  \
0  Bakery & Desserts   56.99       0.0
1  Bakery & Desserts  159.99       0.0
2  Bakery & Desserts   44.99       0.0
3  Bakery & Desserts   39.99       0.0
4  Bakery & Desserts   59.99       0.0

                                          Rating  \
0   Rated 4.3 out of 5 stars based on 265 reviews.
1       Rated 5 out of 5 stars based on 1 reviews.
2   Rated 4.1 out of 5 stars based on 441 reviews.
3  Rated 4.7 out of 5 stars based on 9459 reviews.
4   Rated 4.5 out of 5 stars based on 758 reviews.

                                             Title Currency  \
0  David’s Cookies Mile High Peanut Butter Cake, ...      USD
1  The Cake Bake Shop 8" Round Carrot Cake (16-22...      USD
2  St Michel Madeleine, Classic French Sponge Cak...      USD
3  David's Cookies Butter Pecan Meltaways 32 oz, ...      USD
4  David’s Cookies Premier Chocolate Cake, 7.2 lb...      USD

                                            Feature  \
0  10 Peanut Butter Cake Certified Kosher OU-D 14...
1  Spiced Carrot Cake with Cream Cheese Frosting ...
2  100 count Individually wrapped Made in and Imp...
3  Butter Pecan Meltaways 32 oz 2-Pack No Preserv...
4  10 Four Layer Chocolate Cake Certified Kosher ...

                                Product Description  Rating_Value  \
0  A cake the dessert epicure will die for!Our To...           4.3
1  Due to the perishable nature of this item, ord...           5.0
2  Moist and buttery sponge cakes with the tradit...           4.1
3  These delectable butter pecan meltaways are th...           4.7
4  A cake the dessert epicure will die for!To the...           4.5

   Review_Count  Popularity  Final_Price Rating_Category Popularity_Category
0           265         265        56.99            High                High
1             1           1       159.99            High                 Low
2           441         441        44.99            High                High
3          9459        9459        39.99            High                High
4           758         758        59.99            High                High
```

Interpretasi:

Kolom *Final_Price* dibuat untuk menunjukkan harga setelah dikurangi diskon, sehingga dapat langsung diketahui harga akhir produk. Selain itu, dibuat kolom *Rating_Category* yang mengelompokkan nilai *rating* menjadi kategori *Low*, *Medium*, dan *High* agar lebih mudah dianalisis. Kolom *Popularity* diambil dari jumlah *review*, kemudian dikelompokkan kembali ke dalam *Popularity_Category* untuk menunjukkan tingkat popularitas produk. Dari hasil tersebut terlihat bahwa data menjadi lebih informatif karena tidak hanya menampilkan data asli, tetapi juga hasil olahan seperti harga akhir, kategori *rating*, dan tingkat popularitas produk.

3.2.5. Data *Filtering*

Data *filtering* merupakan proses penyaringan data untuk memilih data yang relevan sesuai dengan kebutuhan analisis. Pada tahap ini dilakukan pemilihan data berdasarkan kriteria

tertentu agar data yang digunakan menjadi lebih fokus dan sesuai dengan tujuan analisis. Proses *filtering* bertujuan untuk mengurangi data yang tidak diperlukan serta memastikan bahwa hanya data yang memiliki nilai yang valid dan relevan yang digunakan.

```
# Menghapus harga tidak valid (<= 0)
gc = gc[gc["Price"] > 0]

# Menghapus diskon tidak valid (< 0)
gc = gc[gc["Discount"] >= 0]

# Menghapus rating tidak valid (> 5)
gc = gc[gc["Rating_Value"] <= 5]

# Menghapus review count tidak valid (< 0)
gc = gc[gc["Review_Count"] >= 0]

# Menghapus data tanpa nama produk
gc = gc[gc["Title"].notnull()]

# Menghapus kategori kosong
gc = gc[gc["Sub Category"].notnull()]

# Reset index setelah filtering
gc = gc.reset_index(drop=True)

# Cek jumlah data setelah filtering
print("Jumlah data setelah filtering:", len(gc))

print(gc.head())
```

```
Jumlah data setelah filtering: 1754
```

```
        Sub Category   Price  Discount  \
0  Bakery & Desserts   56.99       0.0
1  Bakery & Desserts  159.99       0.0
2  Bakery & Desserts   44.99       0.0
3  Bakery & Desserts   39.99       0.0
4  Bakery & Desserts   59.99       0.0

                                          Rating  \
0   Rated 4.3 out of 5 stars based on 265 reviews.
1       Rated 5 out of 5 stars based on 1 reviews.
2   Rated 4.1 out of 5 stars based on 441 reviews.
3  Rated 4.7 out of 5 stars based on 9459 reviews.
4   Rated 4.5 out of 5 stars based on 758 reviews.

                                            Title Currency  \
0  David’s Cookies Mile High Peanut Butter Cake, ...      USD
1  The Cake Bake Shop 8" Round Carrot Cake (16-22...      USD
2  St Michel Madeleine, Classic French Sponge Cak...      USD
3  David's Cookies Butter Pecan Meltaways 32 oz, ...      USD
4  David’s Cookies Premier Chocolate Cake, 7.2 lb...      USD

                                           Feature  \
0  10 Peanut Butter Cake Certified Kosher OU-D 14...
1  Spiced Carrot Cake with Cream Cheese Frosting ...
2  100 count Individually wrapped Made in and Imp...
3  Butter Pecan Meltaways 32 oz 2-Pack No Preserv...
4  10 Four Layer Chocolate Cake Certified Kosher ...

                                Product Description  Rating_Value  \
0  A cake the dessert epicure will die for!Our To...           4.3
1  Due to the perishable nature of this item, ord...           5.0
2  Moist and buttery sponge cakes with the tradit...           4.1
3  These delectable butter pecan meltaways are th...           4.7
4  A cake the dessert epicure will die for!To the...           4.5

   Review_Count  Popularity  Final_Price Rating_Category Popularity_Category
0           265         265        56.99            High                High
1             1           1       159.99            High                 Low
2           441         441        44.99            High                High
3          9459        9459        39.99            High                High
4           758         758        59.99            High                High
```

Interpretasi:

Proses *filtering* dilakukan untuk menghapus data yang tidak valid seperti nilai harga, diskon, *rating*, dan jumlah *review* yang tidak sesuai, serta data yang tidak memiliki informasi penting seperti nama produk dan kategori. Setelah proses tersebut dilakukan, jumlah data yang tersisa ditampilkan untuk memastikan bahwa data yang tidak valid telah berhasil dihapus. Selain itu, ditampilkan beberapa baris data untuk melihat kondisi dataset setelah proses *filtering*, sehingga dapat dipastikan bahwa data sudah lebih bersih.

3.2.6. Data *Aggregation*

Data *aggregation* merupakan proses pengelompokan dan peringkasan data untuk menghasilkan informasi yang lebih sederhana dan mudah dipahami. Pada tahap ini, data yang

memiliki karakteristik yang sama akan dikelompokkan, kemudian dihitung nilai tertentu seperti jumlah atau rata-rata. Proses ini bertujuan untuk melihat pola atau gambaran umum dari data, seperti distribusi jumlah data atau perbandingan nilai antar kelompok. Dengan melakukan agregasi, data yang awalnya detail dapat diringkas menjadi informasi yang lebih jelas dan terstruktur.

```
# Menghitung jumlah produk di setiap Sub Category
product_count = gc.groupby("Sub Category")["Title"].count()

print("Jumlah produk per kategori:")
print(product_count)
```

```
Jumlah produk per kategori:
Sub Category
Bakery & Desserts                33
Beverages & Water               148
Breakfast                        21
Candy                           154
Cleaning Supplies                94
Coffee                           95
Deli                             21
Floral                           75
Gift Baskets                     89
Household                        81
Kirkland Signature Grocery      122
Laundry Detergent & Supplies     39
Meat & Seafood                  144
Organic                          33
Pantry & Dry Goods              171
Paper & Plastic Products         85
Poultry                           9
Seafood                          47
Snacks                          293
Name: Title, dtype: int64
```

Interpretasi:

Kode tersebut digunakan untuk menghitung jumlah produk pada setiap kategori setelah proses *filtering* dilakukan. Dari hasil tersebut terlihat bahwa kategori *Snacks* memiliki jumlah produk paling banyak, diikuti oleh *Pantry & Dry Goods* dan *Candy*. Sementara itu, beberapa kategori memiliki jumlah produk yang lebih sedikit seperti *Poultry* dan *Breakfast*. Hasil ini menunjukkan distribusi produk pada setiap kategori setelah data dibersihkan, sehingga dapat memberikan gambaran kategori mana yang paling dominan dalam dataset.

```
# Menghitung rata-rata harga produk di setiap kategori
avg_price = gc.groupby("Sub Category")["Price"].mean()

print("\nRata-rata harga per kategori:")
print(avg_price)
```

```
Rata-rata harga per kategori:
Sub Category
Bakery & Desserts                 83.414242
Beverages & Water                 36.703514
Breakfast                         13.304286
Candy                             25.069221
Cleaning Supplies                 30.261277
Coffee                            32.880526
Deli                             211.085238
Floral                            61.043333
Gift Baskets                      81.079888
Household                         28.335679
Kirkland Signature Grocery        28.119508
Laundry Detergent & Supplies      33.895128
Meat & Seafood                   218.323194
Organic                           22.420303
Pantry & Dry Goods                29.103450
Paper & Plastic Products          25.667647
Poultry                          144.878889
Seafood                          195.521489
Snacks                            21.544266
Name: Price, dtype: float64
```

Interpretasi:

Kode tersebut digunakan untuk menghitung rata-rata harga produk pada setiap kategori. Dari hasil tersebut terlihat bahwa beberapa kategori memiliki rata-rata harga yang lebih tinggi dibandingkan kategori lainnya. Kategori seperti *Meat & Seafood*, *Seafood*, dan *Deli* memiliki rata-rata harga yang cukup tinggi, sedangkan kategori seperti *Snacks*, *Breakfast*, dan *Candy* memiliki rata-rata harga yang lebih rendah. Hasil ini menunjukkan perbedaan harga antar kategori produk, sehingga dapat memberikan gambaran kategori mana yang cenderung memiliki harga lebih mahal atau lebih terjangkau.

```
# Menghitung rata-rata rating produk di setiap kategori
avg_rating = gc.groupby("Sub Category")["Rating_Value"].mean()
```

```
print("\nRata-rata rating per kategori:")
print(avg_rating)
```

```
Rata-rata rating per kategori:
Sub Category
Bakery & Desserts               3.593939
Beverages & Water               0.710811
Breakfast                       0.452381
Candy                           0.519481
Cleaning Supplies               1.739362
Coffee                          1.758947
Deli                            4.261905
Floral                          3.164000
Gift Baskets                    3.748315
Household                       0.000000
Kirkland Signature Grocery      0.718033
Laundry Detergent & Supplies    1.830769
Meat & Seafood                  3.803472
Organic                         1.121212
Pantry & Dry Goods              1.159064
Paper & Plastic Products        0.683529
Poultry                         4.477778
Seafood                         3.642553
Snacks                          0.553584
Name: Rating_Value, dtype: float64
```

Interpretasi:

Hasil tersebut menunjukkan rata-rata *rating* pada setiap kategori produk. Terlihat bahwa beberapa kategori seperti *Poultry* dan *Deli* memiliki rata-rata *rating* yang tinggi, yang menunjukkan bahwa produk pada kategori tersebut cenderung mendapatkan penilaian yang baik dari pelanggan. Sebaliknya, terdapat beberapa kategori dengan rata-rata *rating* yang rendah, bahkan mendekati nol seperti *Household*. Hal ini dapat menunjukkan bahwa kategori tersebut memiliki sedikit data *rating* atau banyak nilai yang tidak tersedia. Secara keseluruhan, hasil ini memberikan gambaran perbandingan tingkat kepuasan pelanggan pada setiap kategori produk.

```
# Mengetahui kategori mana yang paling populer
total_review = gc.groupby("Sub Category")["Review_Count"].sum()

print("\nTotal review per kategori:")
print(total_review)
```

```
Total review per kategori:
Sub Category
Bakery & Desserts                19790
Beverages & Water                11542
Breakfast                         1424
Candy                            13563
Cleaning Supplies                16824
Coffee                           35724
Deli                             10708
Floral                          141257
Gift Baskets                     43169
Household                            0
Kirkland Signature Grocery       46151
Laundry Detergent & Supplies      9385
Meat & Seafood                   29161
Organic                          11070
Pantry & Dry Goods               14611
Paper & Plastic Products          2773
Poultry                            751
Seafood                          10306
Snacks                           17564
Name: Review_Count, dtype: int64
```

Interpretasi:

Kode tersebut digunakan untuk menghitung total jumlah *review* pada setiap kategori produk. Hasilnya menunjukkan tingkat popularitas masing-masing kategori berdasarkan banyaknya ulasan yang diberikan oleh pelanggan. Dari hasil tersebut terlihat bahwa kategori seperti *Floral*, *Kirkland Signature Grocery*, dan *Gift Baskets* memiliki jumlah *review* yang tinggi, sehingga dapat dianggap sebagai kategori yang lebih populer. Sebaliknya, beberapa kategori seperti *Poultry* dan *Paper & Plastic Products* memiliki jumlah *review* yang lebih rendah, yang menunjukkan tingkat popularitas yang lebih kecil. Secara keseluruhan, hasil ini memberikan gambaran kategori mana yang paling banyak diminati berdasarkan jumlah *review* yang ada.

```
# Mengetahui kategori mana yang sering diskon
avg_discount = gc.groupby("Sub Category")["Discount"].mean()

print("\nRata-rata diskon per kategori:")
print(avg_discount)
```

```
Rata-rata diskon per kategori:
Sub Category
Bakery & Desserts                0.000000
Beverages & Water                0.537162
Breakfast                        0.895238
Candy                            0.248701
Cleaning Supplies                0.839362
Coffee                           0.547368
Deli                             6.190476
Floral                           0.000000
Gift Baskets                     1.685393
Household                        0.000000
Kirkland Signature Grocery       0.217213
Laundry Detergent & Supplies     1.423077
Meat & Seafood                   3.194444
Organic                          0.000000
Pantry & Dry Goods               0.422807
Paper & Plastic Products         0.383529
Poultry                          0.000000
Seafood                          2.765957
Snacks                           0.310580
Name: Discount, dtype: float64
```

Interpretasi:

Kode tersebut digunakan untuk menghitung rata-rata diskon pada setiap kategori produk. Hasilnya menunjukkan seberapa besar diskon yang biasanya diberikan pada masing-masing kategori. Dari hasil tersebut terlihat bahwa kategori seperti *Deli*, *Meat & Seafood*, dan *Seafood* memiliki rata-rata diskon yang lebih tinggi dibandingkan kategori lainnya. Sementara itu, beberapa kategori seperti *Bakery & Desserts*, *Floral*, *Household*, dan *Organic* memiliki nilai diskon 0, yang menunjukkan bahwa produk pada kategori tersebut jarang atau tidak mendapatkan diskon. Secara keseluruhan, hasil ini memberikan gambaran kategori mana yang lebih sering memberikan potongan harga.

```
# Menggabungkan semua hasil agregasi ke satu tabel
summary = gc.groupby("Sub Category").agg({
    "Title": "count",
    "Price": "mean",
    "Rating_Value": "mean",
    "Review_Count": "sum",
    "Discount": "mean"
})
```

```
# Mengganti nama kolom agar lebih jelas
summary.columns = [
    "Total_Product",
    "Avg_Price",
    "Avg_Rating",
    "Total_Review",
    "Avg_Discount"
]

print("\nSUMMARY PER KATEGORI:")
print(summary)
```

```
SUMMARY PER KATEGORI:
                              Total_Product   Avg_Price  Avg_Rating  \
Sub Category
Bakery & Desserts                        33   83.414242    3.593939
Beverages & Water                       148   36.703514    0.710811
Breakfast                                21   13.304286    0.452381
Candy                                   154   25.069221    0.519481
Cleaning Supplies                        94   30.261277    1.739362
Coffee                                   95   32.880526    1.758947
Deli                                     21  211.085238    4.261905
Floral                                   75   61.043333    3.164000
Gift Baskets                             89   81.079888    3.748315
Household                                81   28.335679    0.000000
Kirkland Signature Grocery              122   28.119508    0.718033
Laundry Detergent & Supplies             39   33.895128    1.830769
Meat & Seafood                          144  218.323194    3.803472
Organic                                  33   22.420303    1.121212
Pantry & Dry Goods                      171   29.103450    1.159064
Paper & Plastic Products                 85   25.667647    0.683529
Poultry                                   9  144.878889    4.477778
Seafood                                  47  195.521489    3.642553
Snacks                                  293   21.544266    0.553584

                              Total_Review  Avg_Discount
Sub Category
Bakery & Desserts                    19790      0.000000
Beverages & Water                    11542      0.537162
Breakfast                             1424      0.895238
Candy                                13563      0.248701
Cleaning Supplies                    16824      0.839362
Coffee                               35724      0.547368
Deli                                 10708      6.190476
Floral                              141257      0.000000
Gift Baskets                         43169      1.685393
Household                                0      0.000000
Kirkland Signature Grocery           46151      0.217213
Laundry Detergent & Supplies          9385      1.423077
Meat & Seafood                       29161      3.194444
Organic                              11070      0.000000
Pantry & Dry Goods                   14611      0.422807
Paper & Plastic Products              2773      0.383529
Poultry                                751      0.000000
Seafood                              10306      2.765957
Snacks                               17564      0.310580
```

Interpretasi:
Kode tersebut digunakan untuk menggabungkan beberapa hasil perhitungan seperti jumlah produk, rata-rata harga, rata-rata *rating*, total *review*, dan rata-rata diskon ke dalam satu tabel ringkasan per kategori. Dari hasil tersebut terlihat bahwa setiap kategori memiliki perbedaan karakteristik. Beberapa kategori memiliki jumlah produk yang banyak, sementara kategori lain memiliki harga rata-rata yang lebih tinggi. Selain itu, terdapat kategori dengan jumlah *review* yang besar yang menunjukkan tingkat popularitas yang tinggi, serta kategori dengan nilai diskon yang lebih besar dibandingkan kategori lainnya.

3.3. Data *Warehouse* (Star Schema)

Data *warehouse* merupakan sistem penyimpanan data yang dirancang untuk mendukung proses analisis dan pengambilan keputusan. Pada penelitian ini, data *warehouse* dibangun menggunakan model *star schema*, yaitu struktur yang terdiri dari satu tabel fakta (*fact table*) yang terhubung dengan beberapa tabel dimensi (*dimension table*). Model *star schema* dipilih karena memiliki struktur yang sederhana dan mudah digunakan untuk proses analisis. Tabel fakta berisi data utama seperti harga, diskon, *rating*, dan jumlah *review*, sedangkan tabel dimensi berisi informasi pendukung seperti kategori dan produk. Perancangan data *warehouse* dilakukan setelah proses transformasi data selesai, sehingga data yang dimasukkan ke dalam tabel sudah dalam kondisi bersih dan terstruktur.

```
# Ambil kategori unik
dim_category = gc[["Sub Category"]].drop_duplicates().reset_index(drop=True)

# Tambahkan ID (primary key)
dim_category["Category_ID"] = dim_category.index + 1

# Urutkan kolom
dim_category = dim_category[["Category_ID", "Sub Category"]]

print(dim_category.head())
```

```
   Category_ID       Sub Category
0            1  Bakery & Desserts
1            2  Beverages & Water
2            3          Breakfast
3            4              Candy
4            5  Cleaning Supplies
```

Interpretasi:

Kode tersebut digunakan untuk membuat tabel dimensi kategori dengan mengambil nilai unik dari kolom *Sub Category*. Setiap kategori kemudian diberikan ID sebagai *primary key* untuk membedakan setiap data. Hasilnya menunjukkan bahwa setiap kategori memiliki identitas unik yang dapat digunakan dalam proses pengolahan data selanjutnya, seperti pada pembuatan data *warehouse*.

```
# Ambil informasi produk
dim_product = gc[[
    "Title",
    "Feature",
    "Product Description",
    "Currency"
]].drop_duplicates().reset_index(drop=True)

# Tambahkan Product_ID
dim_product["Product_ID"] = dim_product.index + 1

# Urutkan kolom
dim_product = dim_product[[
    "Product_ID",
    "Title",
    "Feature",
    "Product Description",
    "Currency"
]]
print(dim_product.head())
```

```
   Product_ID                                              Title  \
0           1  David’s Cookies Mile High Peanut Butter Cake, ...
1           2  The Cake Bake Shop 8" Round Carrot Cake (16-22...
2           3  St Michel Madeleine, Classic French Sponge Cak...
3           4  David's Cookies Butter Pecan Meltaways 32 oz, ...
4           5  David’s Cookies Premier Chocolate Cake, 7.2 lb...

                                                 Feature  \
0  10 Peanut Butter Cake Certified Kosher OU-D 14...
1  Spiced Carrot Cake with Cream Cheese Frosting ...
2  100 count Individually wrapped Made in and Imp...
3  Butter Pecan Meltaways 32 oz 2-Pack No Preserv...
4  10 Four Layer Chocolate Cake Certified Kosher ...

                                  Product Description Currency
0  A cake the dessert epicure will die for!Our To...      USD
1  Due to the perishable nature of this item, ord...      USD
2  Moist and buttery sponge cakes with the tradit...      USD
3  These delectable butter pecan meltaways are th...      USD
4  A cake the dessert epicure will die for!To the...      USD
```

Interpretasi:

Kode tersebut digunakan untuk membuat tabel dimensi produk dengan mengambil informasi unik terkait produk seperti nama, fitur, deskripsi, dan mata uang. Data yang duplikat dihapus agar setiap produk hanya muncul satu kali. Selanjutnya, setiap produk diberikan ID sebagai penanda unik. Hasilnya adalah tabel yang berisi data produk yang sudah rapi dan dapat digunakan sebagai referensi utama dalam pengolahan data selanjutnya.

```
# Menghubungkan Category ke Product
gc = gc.merge(dim_category, on="Sub Category", how="left")

# Menghubungkan Product ke Data
gc = gc.merge(dim_product, on=["Title","Feature","Product Description","Currency"], how="left")
```

Interpretasi:

Kode tersebut digunakan untuk menghubungkan data utama dengan tabel dimensi yang telah dibuat sebelumnya. Proses ini dilakukan dengan cara menggabungkan data berdasarkan kolom yang sama. Hasilnya, setiap data kini memiliki *Category_ID* dan *Product_ID* sehingga data menjadi lebih terstruktur.

```
# Membuat Fact Table
fact_table = gc[[
    "Product_ID",
    "Category_ID",
    "Price",
    "Discount",
    "Final_Price",
    "Rating_Value",
    "Review_Count"
]]

print(fact_table.head())
```

```
   Product_ID  Category_ID   Price  Discount  Final_Price  Rating_Value  \
0           1            1   56.99       0.0        56.99           4.3
1           2            1  159.99       0.0       159.99           5.0
2           3            1   44.99       0.0        44.99           4.1
3           4            1   39.99       0.0        39.99           4.7
4           5            1   59.99       0.0        59.99           4.5

   Review_Count
0           265
1             1
2           441
3          9459
4           758
```

Interpretasi:

Kode tersebut digunakan untuk membuat tabel fakta dengan mengambil data utama seperti ID produk, ID kategori, harga, diskon, harga akhir, *rating*, dan jumlah *review*. Hasilnya adalah tabel yang berisi data transaksi atau data utama yang sudah terhubung dengan tabel dimensi. Tabel ini nantinya digunakan sebagai sumber utama untuk analisis dalam data *warehouse*.

3.4. *Load*

Tahap *load* merupakan proses memasukkan data yang telah melalui tahap transformasi ke dalam struktur data *warehouse* yang telah dirancang sebelumnya. Pada tahap ini, data dimasukkan ke dalam tabel fakta dan tabel dimensi sesuai dengan model *star schema*. Proses

load dilakukan dengan memindahkan data hasil pengolahan ke dalam tabel dimensi seperti data kategori dan produk, serta ke dalam tabel fakta yang berisi data utama seperti harga, diskon, *rating*, dan jumlah *review*. Tujuan dari tahap ini adalah agar data yang telah bersih dan terstruktur dapat tersimpan dengan baik dalam data *warehouse* sehingga siap digunakan untuk proses analisis.

```
# Load ke CSV
dim_category.to_csv("dim_category.csv", index=False)
dim_product.to_csv("dim_product.csv", index=False)
fact_table.to_csv("fact_table.csv", index=False)

print("Data berhasil disimpan ke file CSV!")
```

```
Data berhasil disimpan ke file CSV!
```

Interpretasi:
Kode tersebut digunakan untuk menyimpan data hasil pengolahan ke dalam file CSV. Tabel dimensi seperti *dim_category* dan *dim_product*, serta tabel fakta *fact_table*, disimpan sebagai file terpisah. Proses ini merupakan tahap *load*, dimana data yang telah dibersihkan dan disusun dalam bentuk *star schema* disimpan sehingga dapat digunakan kembali untuk analisis. Pesan yang ditampilkan menunjukkan bahwa proses penyimpanan data telah berhasil dilakukan.

BAB IV
ANALISIS DATA

4.1. Analisis Jumlah Produk per Kategori

Visualisasi ini menggunakan *Bar Chart* untuk menampilkan jumlah produk pada setiap kategori.

- *Axis* (X): *Sub Category*
- *Values* (Y): Jumlah Produk (*count of product*)

Visualisasi ini bertujuan untuk mengetahui distribusi jumlah produk pada masing-masing kategori.

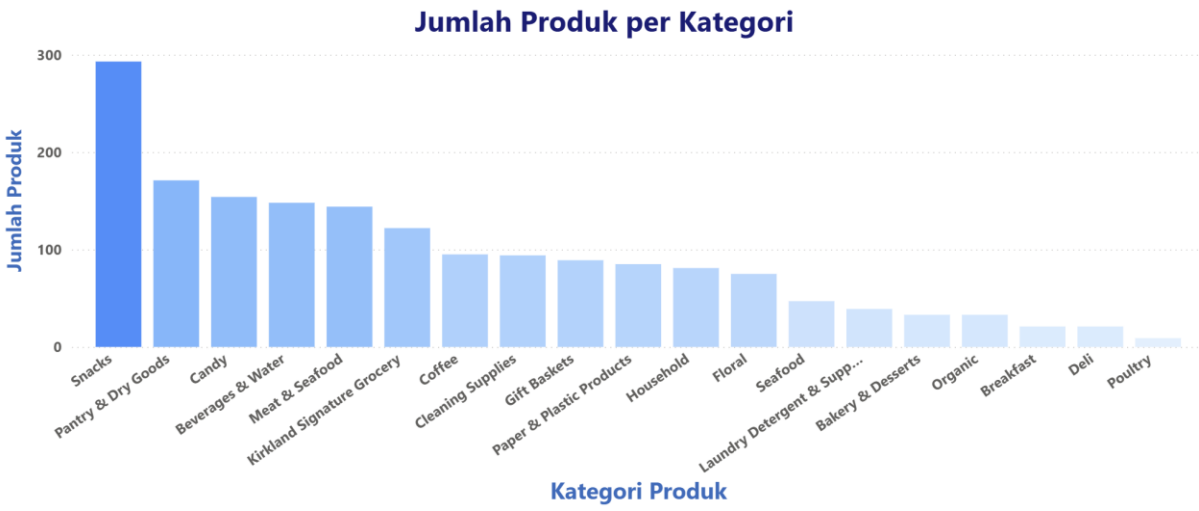

Gambar 4.1. Analisis Jumlah Produk per Kategori

Berdasarkan grafik, kategori *Snacks* memiliki jumlah produk paling banyak dibandingkan kategori lainnya. Hal ini menunjukkan bahwa kategori tersebut memiliki variasi produk yang tinggi serta kemungkinan menjadi salah satu fokus utama dalam penyediaan produk.

Kategori seperti *Pantry & Dry Goods*, *Candy*, dan *Beverages & Water* juga memiliki jumlah produk yang cukup besar. Hal ini mengindikasikan bahwa kategori tersebut termasuk dalam kategori utama yang menyediakan kebutuhan sehari-hari dengan variasi produk yang beragam. Di sisi lain, kategori seperti *Poultry*, *Deli*, dan *Breakfast* memiliki jumlah produk yang relatif sedikit. Hal ini dapat menunjukkan bahwa kategori tersebut memiliki keterbatasan variasi produk atau bukan menjadi fokus utama dalam penyediaan barang.

Jika dilihat secara keseluruhan, distribusi jumlah produk cenderung lebih banyak pada kategori makanan ringan dan kebutuhan harian dibandingkan kategori lainnya. Hal ini

menunjukkan bahwa penyediaan produk lebih difokuskan pada kategori dengan permintaan tinggi dan konsumsi yang lebih sering. Selain itu, jumlah produk yang banyak pada suatu kategori tidak selalu menjamin tingginya popularitas atau interaksi pengguna. Oleh karena itu, diperlukan analisis lanjutan dengan mempertimbangkan faktor lain seperti jumlah *review* dan harga untuk mendapatkan gambaran yang lebih menyeluruh. Berdasarkan hal tersebut, informasi ini dapat dimanfaatkan untuk mengidentifikasi kategori dengan variasi produk tinggi serta sebagai dasar dalam menentukan strategi pengelolaan stok dan pengembangan produk.

4.2. Analisis Rata-rata Harga per Kategori

Visualisasi ini menggunakan *Bar Chart* untuk menampilkan rata-rata harga produk pada setiap kategori.

- *Axis* (X): *Sub Category*
- *Values* (Y): *Average of Price* (*Final Price*)

Visualisasi ini bertujuan untuk mengetahui perbandingan rata-rata harga antar kategori produk.

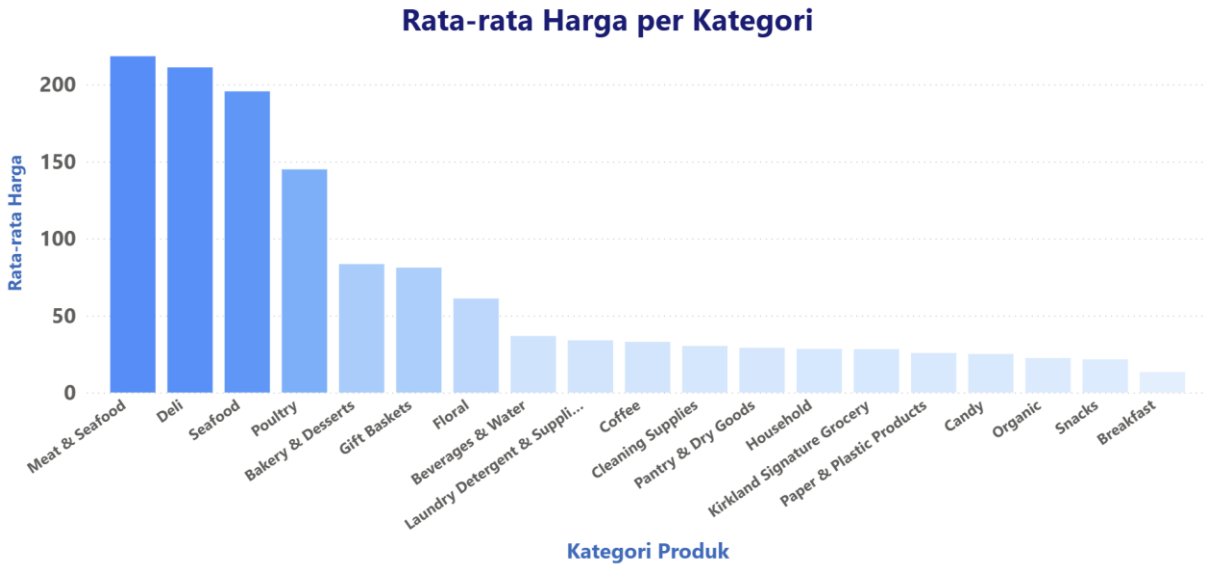

Gambar 4.2. Analisis Rata-rata Harga per Kategori

Berdasarkan grafik, kategori *Meat & Seafood*, *Deli*, dan *Seafood* memiliki rata-rata harga tertinggi dibandingkan kategori lainnya. Hal ini menunjukkan bahwa produk pada kategori tersebut cenderung memiliki nilai jual yang lebih tinggi, yang kemungkinan dipengaruhi oleh faktor kualitas, kesegaran, serta biaya distribusi yang lebih besar.

Kategori seperti *Poultry*, *Bakery & Desserts*, dan *Gift Baskets* juga memiliki rata-rata harga yang cukup tinggi, meskipun tidak setinggi kategori utama. Hal ini mengindikasikan bahwa kategori tersebut berada pada segmen harga menengah hingga premium. Di sisi lain,

kategori seperti *Breakfast*, *Snacks*, dan *Organic* memiliki rata-rata harga yang relatif rendah. Hal ini menunjukkan bahwa kategori tersebut lebih terjangkau dan kemungkinan ditujukan untuk konsumsi sehari-hari dengan target pasar yang lebih luas.

Jika dilihat secara keseluruhan, terdapat perbedaan harga yang cukup signifikan antar kategori. Produk berbasis bahan segar cenderung memiliki harga lebih tinggi, sedangkan produk kemasan atau kebutuhan sehari-hari memiliki harga yang lebih rendah. Selain itu, perbedaan harga ini juga dapat menjadi indikator segmentasi pasar, di mana kategori dengan harga tinggi cenderung menyasar konsumen dengan preferensi kualitas, sedangkan kategori dengan harga rendah lebih berfokus pada volume penjualan dan keterjangkauan. Berdasarkan hal tersebut, informasi ini dapat dimanfaatkan sebagai dasar dalam menentukan strategi penetapan harga, pengelompokan produk, serta penyesuaian target pasar pada masing-masing kategori.

4.3. Analisis Total *Review* per Kategori

Visualisasi ini menggunakan *Bar Chart* untuk menampilkan total jumlah review pada setiap kategori produk.

- *Axis* (X): *Sub Category*
- *Values* (Y): SUM(*review_count*)

Visualisasi ini bertujuan untuk mengetahui tingkat popularitas kategori berdasarkan jumlah ulasan yang diberikan oleh pengguna.

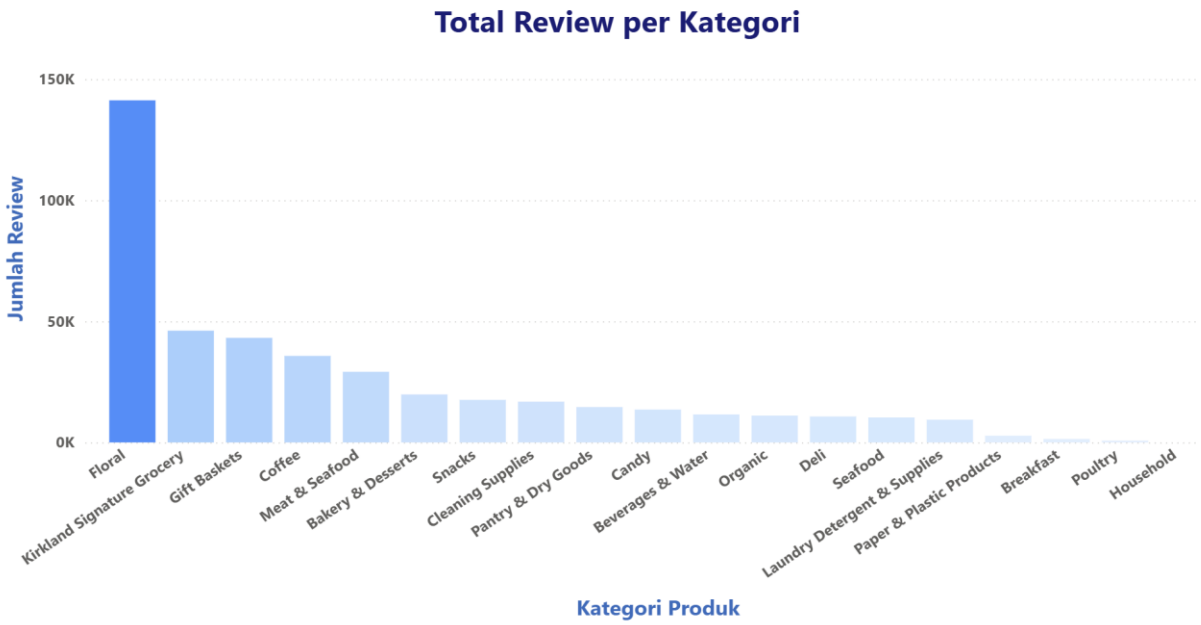

Gambar 4.3. Analisis Total *Review* per Kategori

Berdasarkan grafik, kategori *Floral* memiliki jumlah *review* yang sangat dominan dibandingkan kategori lainnya. Hal ini menunjukkan bahwa kategori tersebut memiliki tingkat interaksi pengguna yang tinggi, baik karena banyaknya transaksi maupun karena pengguna lebih terdorong untuk memberikan ulasan.

Kategori seperti *Kirkland Signature Grocery*, *Gift Baskets*, dan *Coffee* juga menunjukkan jumlah *review* yang cukup besar. Ini mengindikasikan bahwa kategori tersebut memiliki tingkat popularitas yang baik dan cukup sering dibeli oleh konsumen. Di sisi lain, kategori seperti *Household*, *Poultry*, dan *Breakfast* memiliki jumlah *review* yang relatif rendah. Kondisi ini bisa disebabkan oleh rendahnya jumlah pembelian, keterbatasan variasi produk, atau pengguna yang cenderung tidak memberikan ulasan pada kategori tersebut.

Jika dilihat lebih lanjut, jumlah *review* tidak selalu sebanding dengan jumlah produk dalam suatu kategori. Artinya, kategori dengan produk yang banyak belum tentu memiliki tingkat *engagement* yang tinggi. Hal ini menunjukkan bahwa faktor seperti kualitas produk, pengalaman pengguna, dan kepuasan pelanggan juga berperan penting dalam mendorong pengguna untuk memberikan ulasan. Selain itu, tingginya jumlah *review* pada suatu kategori juga dapat menjadi indikator kepercayaan konsumen. Semakin banyak ulasan yang tersedia, semakin besar kemungkinan calon pembeli merasa yakin terhadap produk dalam kategori tersebut.

Berdasarkan hal tersebut, informasi ini dapat dimanfaatkan untuk mengidentifikasi kategori dengan tingkat *engagement* tinggi, serta sebagai dasar dalam menentukan strategi peningkatan interaksi pengguna, khususnya pada kategori dengan jumlah *review* yang masih rendah. Selain itu, kategori dengan *review* tinggi dapat dijadikan fokus utama dalam strategi promosi dan pengembangan produk. Sementara itu, kategori dengan *review* rendah dapat dievaluasi lebih lanjut untuk meningkatkan daya tarik dan keterlibatan pengguna.

4.4. Analisis Rata-rata *Rating* per Kategori

Visualisasi ini menggunakan *Bar Chart* untuk menampilkan rata-rata *rating* produk pada setiap kategori.

- *Axis* (X): *Sub Category*
- *Values* (Y): *Average of Rating*

Visualisasi ini bertujuan untuk mengetahui tingkat kepuasan pengguna terhadap produk pada masing-masing kategori.

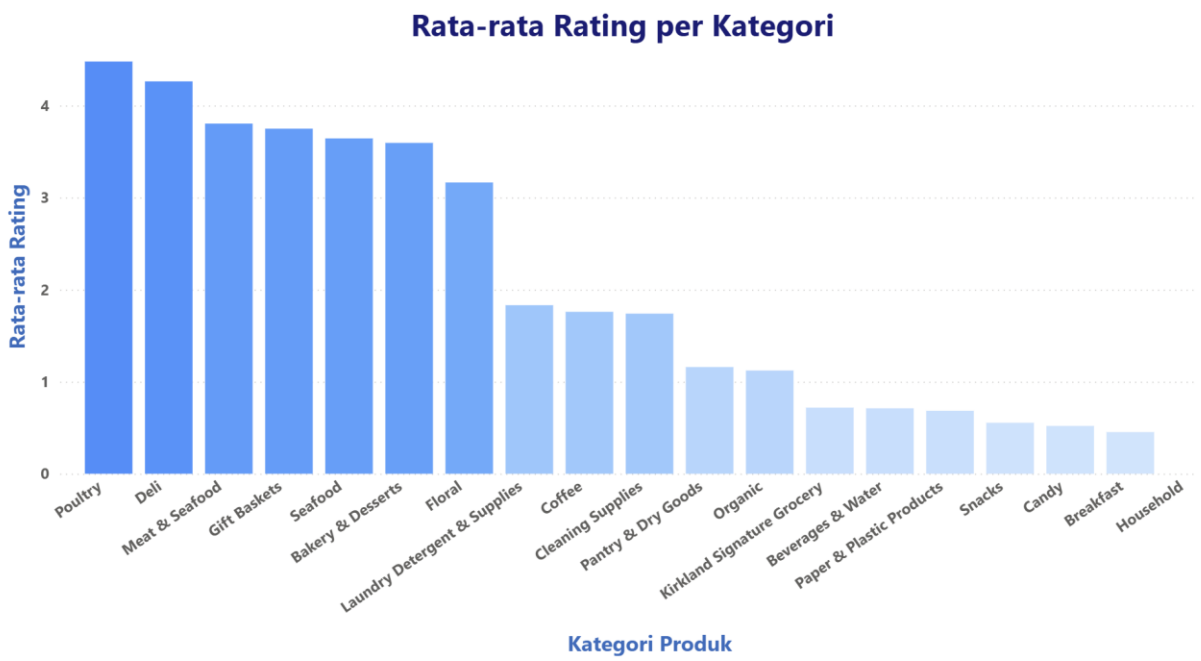

Gambar 4.4. Analisis Rata-rata *Rating* per Kategori

Berdasarkan grafik, kategori *Poultry* dan *Deli* memiliki rata-rata *rating* tertinggi dibandingkan kategori lainnya. Hal ini menunjukkan bahwa produk dalam kategori tersebut memiliki tingkat kepuasan pengguna yang sangat baik, yang kemungkinan disebabkan oleh kualitas produk yang tinggi atau pengalaman pengguna yang positif.

Kategori seperti *Meat & Seafood*, *Gift Baskets*, dan *Seafood* juga memiliki *rating* yang relatif tinggi. Hal ini mengindikasikan bahwa kategori tersebut secara umum mampu memenuhi ekspektasi konsumen. Di sisi lain, kategori seperti *Household*, *Breakfast*, dan *Candy* memiliki rata-rata *rating* yang lebih rendah. Hal ini menunjukkan adanya kemungkinan ketidaksesuaian antara harapan dan pengalaman pengguna terhadap produk dalam kategori tersebut.

Jika dilihat lebih lanjut, *rating* memberikan gambaran kualitas yang berbeda dibandingkan jumlah produk atau jumlah *review*. Kategori dengan jumlah produk banyak belum tentu memiliki *rating* tinggi, sehingga menunjukkan bahwa kuantitas tidak selalu sejalan dengan kualitas. Selain itu, terdapat kemungkinan bahwa kategori dengan harga tinggi cenderung memiliki *rating* yang lebih baik, karena konsumen memiliki ekspektasi yang lebih tinggi terhadap kualitas produk. Namun, hal ini tetap perlu dianalisis lebih lanjut dengan menghubungkan variabel harga dan *rating*. Berdasarkan hal tersebut, informasi ini dapat dimanfaatkan untuk mengevaluasi kualitas produk pada setiap kategori, serta sebagai dasar

dalam meningkatkan kualitas layanan atau produk pada kategori dengan *rating* yang masih rendah.

4.5. Analisis Top 10 Produk Terpopuler

Visualisasi ini menggunakan *Bar Chart* untuk menampilkan 10 produk dengan jumlah *review* tertinggi.

- *Axis* (X): Nama Produk
- *Values* (Y): SUM(*review_count*)

Visualisasi ini bertujuan untuk mengidentifikasi produk yang paling populer berdasarkan jumlah ulasan yang diberikan oleh pengguna.

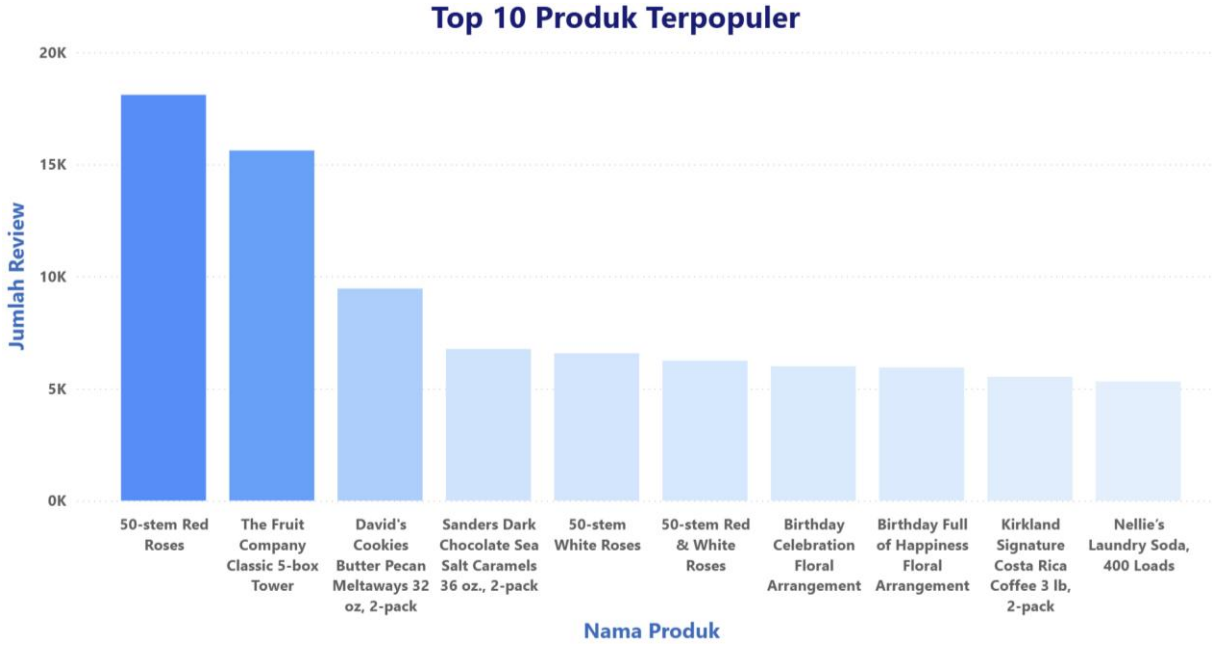

Gambar 4.5. Analisis Top 10 Produk Terpopuler

Berdasarkan grafik, produk *50-stem Red Roses* memiliki jumlah *review* paling tinggi dibandingkan produk lainnya. Hal ini menunjukkan bahwa produk tersebut memiliki tingkat popularitas yang sangat tinggi dan kemungkinan menjadi salah satu produk unggulan yang banyak diminati oleh konsumen.

Produk seperti *The Fruit Company Classic 5-box Tower* dan *David's Cookies Butter Pecan Meltaways* juga memiliki jumlah *review* yang cukup besar. Hal ini mengindikasikan bahwa produk-produk tersebut memiliki daya tarik yang kuat dan sering dipilih oleh pengguna.

Jika dilihat secara keseluruhan, sebagian besar produk dalam daftar ini berasal dari kategori *floral* dan *gift*. Hal ini menunjukkan bahwa produk yang bersifat hadiah atau memiliki

nilai emosional cenderung lebih banyak mendapatkan perhatian serta ulasan dari pengguna. Namun demikian, terdapat juga beberapa produk dari kategori kebutuhan sehari-hari seperti kopi dan produk rumah tangga. Hal ini menunjukkan bahwa popularitas tidak hanya dipengaruhi oleh jenis produk, tetapi juga oleh tingkat penggunaan dan kebutuhan konsumen terhadap produk tersebut. Selain itu, jumlah *review* yang tinggi pada produk-produk ini dapat menjadi indikator kepercayaan konsumen. Produk dengan banyak ulasan cenderung lebih dipercaya oleh calon pembeli karena dianggap telah digunakan dan dinilai oleh banyak pengguna. Berdasarkan hal tersebut, informasi ini dapat dimanfaatkan untuk mengidentifikasi produk unggulan yang perlu dipertahankan, serta sebagai dasar dalam menentukan strategi promosi dan pengembangan produk di masa mendatang.

BAB V
PENUTUP

5.1. Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa data penjualan pada *grocery store* memiliki potensi yang besar untuk diolah menjadi informasi yang bermanfaat. Pada kondisi awal, dataset masih memiliki berbagai permasalahan, seperti data yang tidak konsisten, adanya nilai kosong, serta format data yang belum sesuai untuk analisis. Oleh karena itu, dilakukan proses ETL (*Extract*, *Transform*, *Load*) untuk membersihkan, menyesuaikan, dan mempersiapkan data agar dapat digunakan secara optimal. Perancangan data *warehouse* menggunakan pendekatan *star schema* terbukti mampu membuat data menjadi lebih terstruktur dan sistematis. Hal ini memudahkan dalam proses analisis data, baik berdasarkan kategori produk maupun atribut lainnya.

Hasil analisis menunjukkan bahwa terdapat perbedaan jumlah produk, harga rata-rata, tingkat *rating*, serta tingkat popularitas pada setiap kategori. Informasi tersebut memberikan gambaran yang jelas mengenai karakteristik produk serta preferensi pelanggan. Dengan demikian, penerapan *Business Intelligence* melalui data *warehouse* dapat membantu dalam menghasilkan informasi yang mendukung proses pengambilan keputusan secara lebih efektif dan tepat.

5.2. Saran

Berdasarkan penelitian yang telah dilakukan, terdapat beberapa saran untuk pengembangan selanjutnya, yaitu:

1. Sebaiknya menggunakan dataset yang lebih lengkap dan beragam agar hasil analisis menjadi lebih akurat dan bisa mewakili kondisi yang sebenarnya. Hal ini penting karena pada data yang digunakan masih terdapat beberapa keterbatasan.
2. Proses pengolahan data (ETL) dapat dikembangkan lagi dengan menggunakan *tools* atau metode yang lebih canggih, sehingga proses pembersihan dan pengolahan data bisa lebih cepat dan efisien.
3. Analisis data dapat diperluas, misalnya dengan membuat *dashboard* atau melakukan analisis yang lebih mendalam, agar informasi yang dihasilkan lebih mudah dipahami dan bisa digunakan untuk membantu pengambilan keputusan.